

פרויקט גמר

שיפור היכולת לחזות איחורים ואי הגעות של מטופלים במכון פיזיותרפיה

בהנחיית פרופ' יוסי בוקצ'ין

קבוצה 8:

זינה גדעון 211920772

קורן גרנות 205894702

ג'וזף גליאנוס 211585997

שיר עדני 206491425

תוכן עניינים

2	תוכן עניינים
3	תקציר מנהלים
4	פרק 1 - מבוא
5	פרק 2 - הצגת הארגון
5	2.1 מידע כללי - מכון פיזיותרפיה אבן גבירול
6	2.2 מבנה ארגוני של מכון הפיזיותרפיה -
6	2.3 נתונים כמותיים/טכניים על מכון הפיזיותרפיה -
8	פרק 3 - הצגת הסביבה העסקית
8	3.1 הצגת השוק-
9	3.2 קהל יעד-
10	3.3 ניתוח S.W.O.T-
12	פרק 4 - הצגת התשתית התפעולית
12	4.1 תהליך קליטת מטופל חדש למכון הפיזיותרפיה-
14	פרק 5 - הצגת הבעיה
14	5.1 מבוא-
14	5.2 הצגת הבעיות-
15	5.2 מטרות הפרויקט
17	5.3 כלים הנדסיים לפתרון ומילות מפתח
19	פרק 6 - סקירת ספרות
19	6.1 הקדמה
20	6.2 רקע תיאורטי-
21	6.3 מחקרים קודמים על איחורים וביטולים במכונים רפואיים
21	6.4 טכנולוגיות וכלים לחיזוי
24	6.5 גורמים המשפיעים על איחורים וביטולים
24	6.6 יישומים קודמים ותרשימי בינה מלאכותית
26	פרק 7 - ניתוח סטטיסטי לבעיית האיחורים
26	7.1 מבוא
26	7.2 ניתוח מקדים
28	7.3 ניתוח סטטיסטי היסקי
32	7.4 הצעות לפתרונות:
32	7.5 סיכום
33	פרק 8 - פיתוח מודל לחיזוי הברזות
39	פרק 9 - כדאיות כלכלית
42	פרק 10 - דיון ומסקנות
43	פרק 11 - נספחים
51	12. ביבליוגרפיה

תקציר מנהלים

דו"ח זה עוסק בפתרון בעיית הברזות ואיחורים במכון פיזיותרפיה, המציע טיפולים למטופלים 6 ימים בשבוע בשעות הפעילות המקובלות. המכון מתפעל פיזיותרפיסטים במשמרות, ובנוסף לטיפולים, הפיזיותרפיסטים עוסקים בעבודות נלוות כמו תיעוד טיפולים והתייעצות עם צוותים רפואיים.

במקרים שבהם הפיזיותרפיסטים נמצאים בטיפול או בעיסוק אחר, הם לא זמינים לקבל את המטופלים הממתינים או המטופלים החדשים. עומס העבודה במכון אינו קבוע ומשתנה בהתאם למספר המטופלים ושעות היום.

הבעיה המרכזית שעליה אנו מתמקדים בדו"ח זה היא איחורים ושיעור אי-הגעות גבוה של מטופלים לפגישות הפיזיותרפיה, המובילים לבזבז זמן יקר ולפגיעה בפעילות המכון. יעדי המכון לשנת 2023 היו להגיע ל-95% מהפגישות המתוכננות ולהפחית שיעור אי-הגעות ל-5%.

במהלך ניתוח הנתונים, השתמשנו בכלי למידת מכונה כדי לנתח דפוסי איחור ואי-הגעה ולחזות התנהגויות עתידיות של מטופלים. למדנו את המודלים על נתוני עבר של נוכחות מטופלים, והצלחנו ליצור מערכת חיזוי שמתריעה מראש על סיכויי לאי-הגעה או איחור.

באמצעות מודלים לחיזוי כמו עצי החלטה ורשתות נוירונים, הצלחנו לזהות משתנים מרכזיים המשפיעים על ההגעה, כגון זמן מאז הפגישה האחרונה, זמן בפיזיותרפיה ושביעות רצון המטופלים. הפעלת המודלים סייעה בהצעת שינויים בשיבוץ הפגישות והתאמות אישיות למטופלים, באופן שמאפשר לא רק הפחתת עלויות אלא גם שיפור השירות.

דו"ח זה מפרט את כל השלבים שביצענו ומציג את הפתרונות הפוטנציאליים שזוהו באמצעות למידת מכונה. אנו סבורים כי הפתרונות שהוצעו יובילו לשיפור משמעותי בהפחתת האיחורים וההברזות, ובכך ישפרו את פעילות מכון הפיזיותרפיה ואת שביעות רצון המטופלים.

רשימת מילות מפתח: מכון פיזיותרפיה, איחורים, הברזות, למידת מכונה, חיזוי.

פרק 1 - מבוא

פרויקט זה מהווה את פרויקט הגמר במסגרת התואר בהנדסת תעשייה וניהול באוניברסיטת תל אביב (שנה ד'). בפרויקט זה נבחר הארגון : 'מכון פיזיותרפיה אבן גבירול' אשר ממוקם ברחוב אבן גבירול, תל אביב. מכון הפיזיותרפיה בבעלותו של עפיף חורי - פיזיותרפיסט, בוגר אוניברסיטת תל אביב משנת 1986. מכון פיזיותרפיה מספק טיפולי פיזיותרפיה למבוטחי קופות החולים "לאומית", "כללית מושלם" ו"מכבי" וכן מקבל מטופלים באופן פרטי.

מטרות הפרויקט הינן בחינה לעומק של כמות 'המבריזים' מטיפולי פיזיותרפיה, מציאת גורמים משותפים להם, ניתוח נתוני המערכת שברשותנו וזיהוי צווארי בקבוק. מטרת העל של הפרויקט היא גם להציע פתרון בו נתמקד בהקמת מערכת ממוחשבת לחיזוי אי הגעות, שתשפר את ניהול הזמן במכונים ותסייע למטפלים במתן טיפול טוב יותר.

איש הקשר בפרויקט שלנו הינו בעל המכון - מר עפיף חורי, וכן המזכירה הראשית - יפית שעוזרת לנו להבין באופן מפורט כיצד הדברים מתנהלים ביומן הממוחשב. מנחה הפרויקט - יוסי בוקצ'ין



פרק 2 - הצגת הארגון

2.1 מידע כללי - מכון פיזיותרפיה אבן גבירול

מכון פיזיותרפיה 'אבן גבירול 186' היא ארגון המתמחה בספק שירותי פיזיותרפיה מתקדמים ומגוונים לקהל הרחב. החברה הנ"ל מייצגת אחת מבין כמה מכוני פיזיותרפיה שאותם מנהל עפיף חורי, אך הפרויקט שלנו מתמקד רק בסוגיות העולות ממכון הפיזיותרפיה שממוקם באבן גבירול, תל אביב. החברה מתמקדת בסיפוק טיפולים פיזיותרפיים לאנשים הסובלים מפגיעות פיזיות או רפואיות שונות, המצריכות התערבות מקצועית לשקיעה בשיקום ושיפור תפקודי הגוף. המכון מציע מגוון רחב של שירותים הכוללים:

- טכניקות ידניות (Manual therapy) טכניקות ידניות הן חלק חשוב בטיפול הפיזיותרפי הוא הטיפול הידני (Manual therapy) והן מהוות ייסוד בשיקום מוביליזציות ומניפולציות על פי מייטלנד (Maitland mobilization and manipulation), טיפול לפי שיטת מקנזי (McKenzie technique), מוביליזציות לפי מאליו (Mulligan technique), טכניקות אוסטאופתיות (Myofascial release, Strain counter strain, Muscle energy) מניפולציה לרקמות רכות (Soft tissue manipulation), טכניקות לתנועתיות מערכת העצבים (Neurodynamics)

- אלקטרותרפיה ואולטראסאונד (Electrotherapy and US) טכניקות חשמליות נכללות כחלק מסל השירותים הניתנים בפיזיותרפיה. במצבים אקוטיים לעיתים השימוש בטכניקות ידניות אינו אפשרי ובמקרים אלו יעילות השימוש בטכניקות נוספות חשובה. במכון מכשור חדשני ועדכני, שכולל מגוון זרמים חשמליים תחושתיים, מוטוריים ולהורדת נפיחות: Tens, Interferential, Diadynamic current, Russian current, US, ומכשיר זרמים משולב עם US, טיפול בקור ונום (Termotherapy and Cryotherapy), טיפול בפראפין (Paraffin)


- טייפינג וקינזיוטייפינג (Taping and kinesio-taping) שימוש בטייפינג הינה דרך ייחודית ויעילה לשיפור היעילות ולשמירה על ההישגים שהושגו במהלך הטיפול הפיזיותרפי. מגוון טכניקות טייפינג שונות לייצוב מפרקי, הורדת עומס מרקמות, להורדת כאב, להורדת נפיחות, לשיפור תחושת המצב ולשיפור תפקוד השריר. סוגי החבישות שבשימוש המרפאה כולל: טייפינג קשיח מסוג אנדורה ENDURA טייפ אלסטי מסוג קינזיוטייפינג (Kinesio-taping)

- מתן תרגילים וייעוץ לפעילות גופנית תרגילים הם חלק משמעותי מהשיקום במרבית המטופלים. התאמת התרגילים בעיקר בשלב הראשוני של השיקום הינה חלק חשוב ביותר. תפקיד הפיזיותרפיסט להתאים תרגילים מתוך הסתכלות מעמיקה ואבחון הביומכאני של המטופל. יכלול: אימונים פונקציונאליים (Functional Training), תרגול יציבתי תחושת (Proprioception) תוך שימוש בעזרים שונים (כדור פיזיו, פיתה, גליל), ייעוץ לפעילות גופנית בחדר כושר תוך מתן דגש על שיפור היציבה ושימוש נכון ומושכל בחדר הכושר.

החברה דוגלת באיכות ובמקצועיות גבוהה ומשקיעה בציד ובטכנולוגיה מתקדמת לסיוע בתהליכי השיקום והשיפור הפיזיותרפי של הלקוחות. תפקידה העיקרי של החברה הוא לספק שירות יעיל ואיכותי שמטרתו לשפר את איכות החיים ולהחזיר את התפקוד המלא של הלקוחות שלה.

2.2 מבנה ארגוני של מכון הפיזיותרפיה -

המבנה הארגוני של מכון פיזיותרפיה תל אביב נועד לתמוך במטרה לספק את הטיפול הטוב ביותר למטופלים. ניתן לראות כי המבנה הארגוני אמנם קטן, אך רב יחסית לגודל המכון וזאת תוך קידום תקשורת ושיתוף פעולה בין כל הצוותים המקצועיים על מנת להבטיח תהליך טיפול יעיל לכל מטופל.



תרשים 2.2- לרשום תבניות לכתיבת תרשים ומלל מקדים
*המנהל הוא גם מטפל

2.3 נתונים כמותיים/טכניים על מכון הפיזיותרפיה -

כאמור, קיימים מספר מכוני פיזיותרפיה בבעלותו של מר עפיף חורי, אך הבעיה המרכזית מתמקדת בסניף אבן גבירול תל אביב, ולכן נפרט על הסניף הזה בלבד.

להלן מספר נתונים על מכון הפיזיותרפיה-

- במכון יש מנהל אחד - מר עפיף חורי
- תחתיו ישנם 5 מטפלים שעובדים בימים שונים
- המכון מנוהל ע"י 3 מנהלות אדמיניסטרטיביות שעובדות במשמרות בוקר/ערב
- המכון כולל 6 מיטות טיפולים + חדר טיפולים פרטי עם מיטה נוספת
- רחבה בה יש משקולות, מזרונים
- מכשיר Tense - ארבע יחידות
- מכשיר גלי הלם - יחידה אחת
- מכשיר Tense Vacuum - יחידה אחת
- מכשיר אולטראסאונד - שלושה מכשירים

בשנת 2023 היו-

קבלות של מטופלים	מטופלים אשר המשיכו לסבב טיפול נוסף	מטופלים אשר לא הגיעו לטיפול שקבעו
14,673	1983	1369

יש לציין כי נתונים אלו הגיעו ממאגר נתונים שהיו ברשות המכון וכי ניכר שקובץ זה אינו מעודכן ברובו - למשל אנחנו חוזים כי מספר ההברזות גדול ומשמעותי בהרבה מזה המצוין בקובץ.

נתונים כלכליים-

שכיר המכון	שכר מטפל לשעה (בין המטופל הגיע או לא)	שכר המנהלת האדמיניסטרטיבית
15,000	150-200	10,000

פרק 3 - הצגת הסביבה העסקית

3.1 הצגת השוק-

ענף מכוני הפיזיותרפיה הפרטיים בישראל מהווה נדבך חיוני במערכת הבריאות הלאומית, משלים את השירותים הציבוריים ומספק מענה הולם לביקוש הגובר לטיפול שיקום ובריאות מתקדמים. השוק מתאפיין במבנה תחרותי ומבוזר, המורכב ממגוון רחב של מכונים בגדלים שונים, החל ממרפאות קטנות ועד לרשתות גדולות בעלות פריסה ארצית. מכונים אלו מציעים התמחויות מגוונות, כגון שיקום ספורט, טיפול בבעיות נוירולוגיות, אורתופדיה, ושיקום לאחר ניתוחים, תוך שימת דגש על מתן שירות אישי ושימוש בטכנולוגיות מתקדמות כאמצעי בידול בשוק התחרותי.

הביקוש לשירותי פיזיותרפיה בישראל נמצא במגמת עלייה מתמדת, המונעת על ידי מספר גורמים מרכזיים: הזדקנות האוכלוסייה המגדילה את הצורך בטיפול שיקום, עלייה משמעותית במודעות לחשיבות אורח חיים בריא ופעיל, וגידול במקרי פציעות ספורט ותאונות עבודה. בתגובה לביקוש הגובר, מכוני הפיזיותרפיה מרחיבים את סל השירותים שלהם, מציעים טיפולים פיזיים מותאמים אישית, משלבים מכשור מתקדם כגון רובוטיקה שיקומית ומערכות הדמיה משוכללות, ומשלבים טיפולים משלימים כגון הידרותרפיה, דיקור יבש, ושיטות טיפול חדשניות נוספות.

מגמות בולטות בענף כוללות אימוץ נרחב של טכנולוגיות דיגיטליות, כגון אפליקציות למעקב אחר התקדמות הטיפול ופלטפורמות לתרגול מרחוק, המאפשרות המשכיות טיפולית גם מחוץ למסגרת המכון. בנוסף, ניכרת מגמה של שיתופי פעולה הולכים וגדלים בין מכוני הפיזיותרפיה לבין גורמי רפואה נוספים, כגון רופאי משפחה, אורתופדים, ותזונאים, במטרה לספק למטופלים גישה כוללתית ורב-תחומית לבריאותם. התפתחות נוספת בענף היא הגידול בתיירות רפואית, במיוחד בערים מרכזיות כמו תל אביב, המושכות מטופלים מחו"ל בזכות איכות השירותים הרפואיים והטיפולים המתקדמים המוצעים בישראל.

למרות הפוטנציאל הגדול, הענף מתמודד עם מספר אתגרים משמעותיים. העלויות הגבוהות של טיפולים פרטיים מהוות חסם עבור חלק מהאוכלוסייה, במיוחד לאור המגבלות בכיסוי הביטוחי הציבורי והמשלים. התחרות העזה בשוק מחייבת את המכונים להשקיע באופן מתמיד בציוד חדש, בהכשרה מקצועית של הצוות, ובפיתוח אסטרטגיות שיווק אפקטיביות למשיכת לקוחות ושימורם. בנוסף, הרגולציה המתהדקת בתחום הבריאות מציבה דרישות גוברות לשקיפות, איכות טיפול, ובטיחות המטופל. לצד האתגרים, הענף מציע הזדמנויות משמעותיות לצמיחה והתרחבות. העלייה המתמדת במודעות לחשיבות הבריאות והכושר הגופני פותחת פתח להרחבת סל השירותים, כולל תוכניות מניעה, שיקום מוקדם, וליווי ארוך טווח של מטופלים. הטכנולוגיות החדשות מאפשרות למכונים לשפר את איכות הטיפול, להגדיל את היעילות התפעולית, ולהגיע לקהלי יעד חדשים באמצעות שירותים מקוונים. בנוסף, ההתפתחות בתחום התיירות הרפואית מציעה הזדמנות לפיתוח שווקים חדשים ולהרחבת בסיס הלקוחות מעבר לגבולות המדינה.

כמו כן, יש לציין כי בישראל קיימים שני מסלולים לגישה לשירותי פיזיותרפיה: המסלול הציבורי והמסלול הפרטי. במערכת הבריאות הציבורית, מטופלים מופנים למכוני פיזיותרפיה על ידי רופאים במסגרת קופות החולים או בתי החולים, תוך כיסוי חלקי של עלויות הטיפול. יתרונותיו של מסלול זה כוללים נגישות כלכלית וגישה למומחים ומכשור מתקדם במכונים גדולים, אך הוא מאופיין בתורי המתנה ארוכים ומגבלות על משך המפגשים הטיפוליים. לעומת זאת, המסלול הפרטי מאפשר למטופלים לפנות ישירות למכונים פרטיים או דרך הפניה מרופא פרטי, תוך הנגשת טיפול מהיר, גמישות בבחירת המטפל והמכון, וגישה לטכנולוגיות חדשניות. עם זאת, העלות הגבוהה של הטיפול הפרטי מהווה חסם משמעותי, למרות קיומן של חבילות מוזלות במקרים מסוימים. בעוד ששני המסלולים פועלים במקביל, המערכת הפרטית מציעה יתרונות של מהירות וגמישות, בעוד שהמערכת הציבורית מספקת פתרון נגיש יותר מבחינה כלכלית, תוך פשרה על זמני המתנה והיקף הטיפול. בחירת המסלול המועדף תלויה בצרכים האישיים, במצב הרפואי ובאילוצים הכלכליים של כל מטופל.

לסיכום, ענף מכוני הפיזיותרפיה הפרטיים בישראל נמצא בצומת קריטי של אתגרים והזדמנויות. הצלחה בשוק זה תלויה ביכולתם של המכונים להתאים עצמם באופן מתמיד לדרישות המשתנות של השוק, להשקיע בחדשנות טכנולוגית ומקצועית, ולספק שירות איכותי ומותאם אישית. עם הגידול הצפוי בביקוש לשירותי בריאות ושיקום, ולאור המגמות הדמוגרפיות והחברתיות הנוכחיות, הענף צפוי להמשיך במגמת צמיחה, תוך התמודדות מתמדת עם אתגרי הרגולציה, התחרות הגוברת, והצורך בהתאמה מתמדת לצרכי המטופלים המשתנים. מכונים רבים נוספים העובדים עם קופות החולים ומדורגים גבוה (כולל מכונים פרטיים).

בין המתחרים ניתן למצוא את המוסדות הבאים אשר מדורגים כמקומות ראשונים בתל אביב-

- קליניקה פרטית Physio Quantax המתמחה בטיפולי פיזיותרפיה
- מרכז פיזיותרפיה צהלה ברמת אביב
- מומנטום
- איימקס פיזיותרפיה
- ועוד מכונים רבים וטובים אחרים שעובדים עם הקופות ומדורגים גבוה (ביניהם גם מכונים פרטיים)

3.2 קהל יעד-

מכון פיזיותרפיה אבן גבירול מקבל לטיפול אנשים מגילאים ורקעים שונים, כולל את הבוגרים והצעירים כאחד. במכון נמצאים תושבים מהעיר תל אביב והסביבה, וגם מהסביבה הרחוקה יותר, שמחפשים טיפול פיזיותרפי מקצועי ואיכותי. הלקוחות כוללים אנשים עם פציעות ספורט, בעיות אורתופדיות, ותאונות מכונית, שמחפשים להחזיר את תפקודם הפיזי, לשפר את רמת השיקום, ולהפחית את הכאבים והצרכים הרפואיים. המכון מתמקד בתחומי טיפול שונים ומציע תוכניות אישיות לכל לקוח בהתאם לצרכיו הפיזיים והמרפאים.

קהל היעד של מכוני הפיזיותרפיה הפרטיים בישראל מגוון וכולל קבוצות שונות באוכלוסייה:

1. אוכלוסייה מבוגרת: אנשים בגיל השלישי מהווים קבוצה משמעותית בקהל היעד של מכוני הפיזיותרפיה. עם העלייה בגיל, רבים מתמודדים עם בעיות רפואיות כרוניות כמו כאבי גב, בעיות מפרקים ושיקום לאחר ניתוחים, שדורשים טיפול פיזיותרפי מתמשך.
2. ספורטאים: קבוצה זו כוללת ספורטאים מקצועיים וחובבים כאחד, הזקוקים לשירותי פיזיותרפיה לצורך שיקום מפציעות ספורט, שיפור ביצועים, והפחתת סיכון לפציעות חוזרות.
3. אנשים לאחר תאונות או ניתוחים: קהל יעד חשוב נוסף כולל אנשים שעברו תאונות דרכים, תאונות עבודה, או ניתוחים מורכבים (כמו החלפת מפרקים או ניתוחי עמוד שדרה), הזקוקים לשיקום מקצועי כדי לחזור לתפקוד מלא.
4. פצועי מלחמה: כוללים חיילים ואזרחים שנפגעו במהלך עימותים או פעולות צבאיות. פצועים אלו זקוקים לשיקום אינטנסיבי ולעיתים ממושך כדי להתמודד עם פציעות מורכבות כמו שברים, פגיעות בעמוד השדרה, קטיעות גפיים, פציעות ראש, ופגיעות טראומטיות אחרות. מכוני הפיזיותרפיה מציעים טיפול מותאם אישית שמסייע לשקם את התפקוד הפיזי.
5. אנשים עם בעיות רפואיות כרוניות - אלו כוללים אנשים עם מצבים כמו פיברומיאלגיה, דלקת מפרקים, מחלות נוירולוגיות וכדומה, הדורשים טיפולים פיזיותרפיים מותאמים אישית לשמירה על איכות חיים.
6. נשים בהריון ואחרי לידה - קבוצה זו כוללת נשים הזקוקות לטיפולים פיזיותרפיים לשיפור יציבה, חיזוק שרירי רצפת האגן, והפחתת כאבים הקשורים בהריון ובלידה.
7. ילדים ונוער - מכוני פיזיותרפיה פרטיים מציעים שירותים ייעודיים לילדים ונוער המתמודדים עם בעיות התפתחותיות, בעיות יציבה, או פציעות ספורט.
8. מטופלים בתיירות מרפא - בעיקר בערים כמו תל אביב, קהל יעד נוסף הוא מטופלים מחו"ל המגיעים לישראל כדי לקבל טיפול פיזיותרפי מתקדם.

3.3 ניתוח S.W.O.T

ניתוח S.W.O.T הינו כלי ניתוח ארגונים אשר מאפשר למפות את החוזקות והחולשות של הארגון תוך מציאת ההזדמנויות והאיומים בענף בו הארגון פועל. בעזרת ניתוח S.W.O.T, ניתן לפתח תוכניות פעולה כיצד להשתמש בחוזקות הארגון כדי לנצל הזדמנויות ולנטרל איומים וכן לעבוד על חולשות הארגון בענף בו הוא פועל. נתאר את הפרמטרים לעיל בטבלה מטה, ולאחר מכן נפרט על כל אחד מהם.

חולשות	חוזקות
<ul style="list-style-type: none"> • תשתיות מוגבלות • שיבוצים לא מיטביים • תלות בשוק המקומי 	<ul style="list-style-type: none"> • מיקום מרכזי • צוות מקצועי ומנוסה • מגוון שירותים • מוניטין חיובי

הזדמנויות	איומים
<ul style="list-style-type: none"> • ביקוש מוגבר לטיפול פיזיותרפיה • מלחמה בישראל • טכנולוגיות חדשות • שיתופי פעולה 	<ul style="list-style-type: none"> • מלחמה בישראל • תחרות מוגברת • שינויים רגולטוריים • אי יציבות כלכלית

חוזקות (Strengths)-

- **מיקום מרכזי:** המכון ממוקם בתל אביב, עיר מרכזית ונגישה עם אוכלוסייה גדולה.
- **צוות מקצועי ומנוסה:** המכון מעסיק פיזיותרפיסטים מיומנים ובעלי ניסיון רב.
- **מגוון שירותים:** מציע מגוון רחב של טיפולים ושירותים לפיזיותרפיה, מה שמושך קהל מגוון.
- **מוניטין חיובי:** המכון זוכה להמלצות חיוביות מלקוחות מרוצים, מה שמגביר את האמינות והאמון של הקהל.

חולשות (Weaknesses)-

- **תשתיות מוגבלות:** המקום קטן יחסית, מה שמגביל את כמות הלקוחות שניתן לטפל בהם בו זמנית.
- **שיבוצים לא מיטביים:** לעיתים משובצים עובדים רבים מדי למשמרת או לא מספיק, מה שגורם לחוסר יעילות.
- **תלות בשוק מקומי:** התלות בשוק המקומי יכולה להיות חיסרון במקרה של שינויים כלכליים או דמוגרפיים. כמו למשל השינויים הכלכליים שנבעו ממגפת הקורונה וכן גם במהלך ראשיתה של מלחמת חרבות ברזל.
- **בעיית חניה:** ישנה בעיית חניה באזור, מכון הפיזיותרפיה ממקום ברחוב הראשי של אבן גבירול בו מספר מקומות חניה מאוד קטן. אין מקומות חניה שמורים לעובדים וכן גם למטופלים.

הזדמנויות (Opportunities)-

- **ביקוש מוגבר לטיפול פיזיותרפיה:** עם הגברת המודעות לבריאות ולכושר, הביקוש לשירותי פיזיותרפיה עולה.
- **מלחמה בישראל:** בעקבות מלחמת חרבות ברזל אנשים רבים מצאו זמן לטפל בעצמם ובבריאותם הפיזית, מה שיכול לגרום לעלייה בביקוש.
- **טכנולוגיות חדשות:** אימוץ טכנולוגיות חדשות לטיפול ולניהול המטופלים יכול לשפר את השירותים ולהביא לקוחות חדשים
- **שיתופי פעולה:** יצירת שיתופי פעולה עם בתי חולים, קופות חולים וארגוני בריאות שונים.

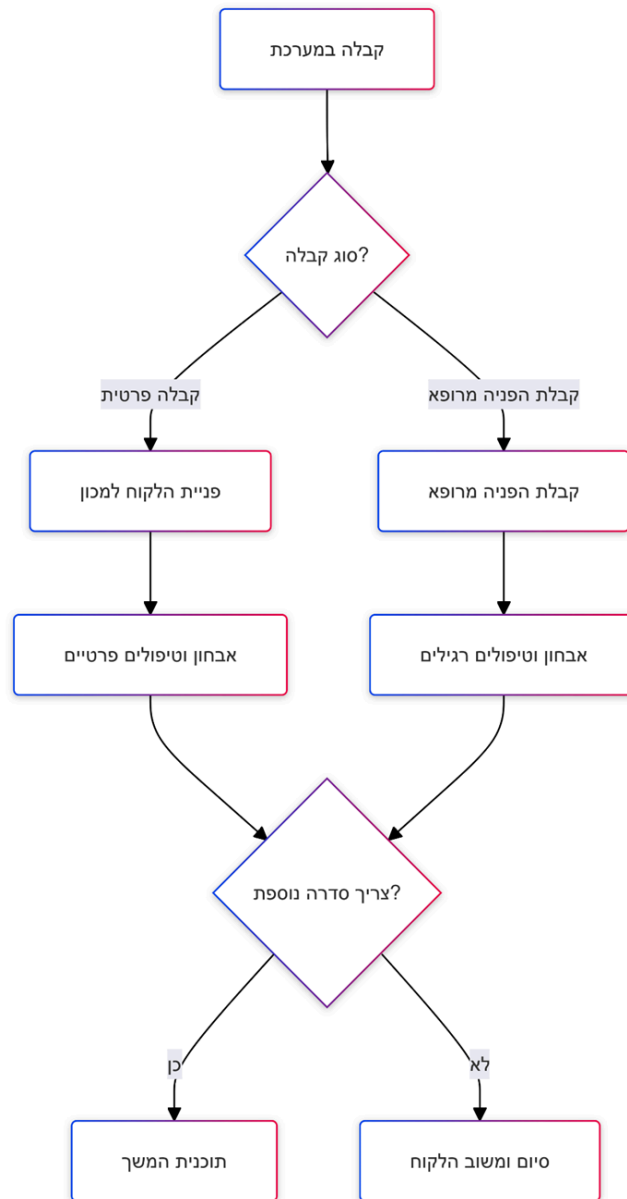
איומים (Threats)-

- **מלחמה בישראל:** המלחמה המתמשכת עלולה לגרום לירידה במספר הלקוחות, לחשש ולחוסר ודאות כלכלית.
- **תחרות מוגברת:** תחרות גוברת ממכונים אחרים, כולל מרפאות פרטיות ובתי חולים באזור
- **שינויים רגולטוריים:** שינויים ברגולציה ובתקנות הבריאות עלולים להוביל לעלויות נוספות ולהשפיע על אופן הפעולה.
- **אי יציבות כלכלית:** המצב הכלכלי עלול להשפיע על היכולת של הלקוחות לשלם עבור טיפולים פרטיים.

פרק 4 - הצגת התשתית התפעולית

4.1 תהליך קליטת מטופל חדש למכון הפיזיותרפיה-

בפסקאות הבאות, יוצג תרשים תהליך קבלת מטופל למכון הפיזיותרפיה. התרשים מתאר את כל שלבי הקבלה, החל מרישום ראשוני ועד לתחילת הטיפול. בהמשך, יובא תיאור מפורט של כל שלב ושלב בתהליך, תוך התמקדות בפעולות הנדרשות ובאנשי הצוות המעורבים. התרשים מתאר את כל שלבי הקליטה למכון, החל מהרישום ראשוני ועד לסוף הטיפול.



1. קבלת הפניה -

- מקבלים הפניות מרופאים, בתי חולים או לקוחות פרטיים
- יוצרים קשר עם המטופל לקבלת מידע:
 - * אבחנה
 - * סיבת ההפניה
 - * היסטוריה רפואית רלוונטית
- מוודאים שהמטופל מבין את הצורך בטיפול ואת התהליך

2. הסדרת תשלום -

- לקוח מבוטח קופת חולים:
- * מוודאים במערכת הקופה שיש התחייבות לתשלום
- * תעריך זהה לכל הקופות: כ-100 ש"ח כולל מע"מ
- לקוח פרטי -
- * תעריך המכון: 300 ש"ח כולל מע"מ

3. תיאום פגישת הערכה ראשונית -

- קביעת תור ראשוני עם הפיזיותרפיסט המתאים
- התחשבות בזמינות המטופל ובלוח הזמנים של המכון
- שליחת הודעת תזכורת למטופל כולל הנחיות להכנה לפגישה

4. אבחון וקביעת סדרת טיפולים -

- הערכה ראשונית של מצב המטופל:
 - * בדיקה גופנית
 - * סקירת היסטוריה רפואית
 - * קביעת מטרות טיפול
- תיאום סדרת טיפולים מותאמת אישית:
 - * קביעת סוגי טיפולים מומלצים
 - * קביעת תדירות הטיפולים

5. סיכום סדרת טיפולים ראשונה והערכה מחדש -

- מעקב אחר התקדמות המטופל במהלך הטיפולים
- ביצוע הערכה מחדש
- תיאום טיפולים נוספים במידת הצורך

6. סיום טיפול ודירוג הלקוח -

- סיכום טיפול:
 - * פגישה מסכמת עם המטופל
 - * הערכת הצלחת הטיפול
 - * מתן המלצות להמשך (תרגילים לשמירה על השיפור, הדרכה למניעת פציעות)
- אפשרות למעקב נוסף ותיאום פגישות ביקורת בעת הצורך
- משוב מטופל:
 - * בקשת משוב על חוויית השירות והטיפול
 - * שימוש במשוב לצורך שיפור השירות במכון.

פרק 5 - הצגת הבעיה

5.1 מבוא-

בעיית הברזות עשויה להיות בעיה מרכזית עבור מכוני פיזיותרפיה, בהקשר של ניהול זמנים ושירות ללקוחות. איחורים יכולים להשפיע באופן ישיר על חוויית הלקוח ועל יעילות הטיפול, בעוד הברזות יכולות לגרום לתחושת רגישות או לאיבוד ביטחון במטופלים.

בעיות איחורים עשויות להתעורר בשל תזמון לא יעיל של טיפולים או עקיפות בשירות הקבוע, מה שיכול להוביל לעיכובים ולא מספיק זמן מטפל עם כל מטופל.

בנוסף, בעיות בהברזות יכולות להשפיע על חוויית הלקוח במקום בכך שהן מקשות על תחושת הנוחות של הלקוח, או שמשפיעות על התמצאותו ואיכות הטיפול הפיזיותרפי שמקבל.

כמו כן, ישנו יתרון כלכלי בזיהוי מוקדם של מאחרים ומבטלים, כיוון שאז ניתן לשבץ לקוחות בהמתנה או להקדים קיימים. הדבר יכול לשפר את תפוקת המכון מבחינת לקוחות, למנוע זמנים בהם המכון משלם למטפל ללא לקוח.

5.2 הצגת הבעיות-

1. **מחסור במידע על איחורים - במכון פיזיותרפיה אבן גבירול נתקלנו בבעיה מובהקת במערכת הנתונים שלהם, המתמקדת ברישום רק כמות הברזות ולא איחורים.**

זאת הובילה לקשיים ניכרים ביכולתנו לחזות ולנהל את האיחורים בצורה אפקטיבית. לכן, החלטנו לבצע תצפיות בשטח על כמות האיחורים כדי להבין איך זה משפיע על פעולותינו ועל חוויית המטופלים. נדון בתוצאות התצפיות ומסקנות בהמשך.

אם כן, גילינו כי בעיית האיחורים גורמת להמתנות מרובות. על כן, החלטנו להעמיק בנושא ולנתח את הבעיה באופן מעמיק יותר (פרק 8).

2. **בעיית הברזות - במכון הפיזיותרפיה שלנו קיימת בעיה מתמשכת של הברזות מצד המטופלים, מה שגורם לשיבושים רבים בתהליך העבודה השוטף.**

ההברזות מביאות לבזבז זמן ומשאבים, פוגעות ביכולת לתכנן את יומו של הצוות הרפואי, ומובילות לאובדן הכנסות. כמו כן, מצבים אלה מקשים על מתן טיפול רציף ואפקטיבי למטופלים.

במסגרת הפרויקט הקרוב, נדון בפתרונות אפשריים לבעיה זו, מתוך מטרה לייעל את תהליך הזימון, לשפר את הקשר עם המטופלים ולהבטיח רציפות טיפולית ואפקטיבית.

3. **מבנה ארגוני - במכון הפיזיותרפיה קיימת בעיה ארגונית שמתבטאת בשיבוץ לא מיטבי של כוח האדם. מתצפיות רבות שביצענו, נמצא כי לעיתים משובצים כמות עובדים שאינה תואמת את גודל המקום ואת הצרכים בפועל.**

לדוגמה, ישנם מקרים בהם משובצים יותר ממזכירה אחת למשמרת, דבר שגורם לבזבז משאבים ולפגיעה ביעילות התפעולית. מנגד, ישנם מצבים בהם אין מספיק מיטות טיפול זמינות למטופלים, מה שמוביל לעומס עבודה ולירידה באיכות השירות.

בעיות אלו מצריכות בחינה מעמיקה של שיבוץ העובדים ושיפור בתהליכי הניהול הארגוני, מתוך מטרה לייעל את העבודה, לחסוך במשאבים ולספק שירות איכותי ורציף למטופלים.

לסיכום, במכון הפיזיותרפיה שלנו מתמודדים עם מגוון בעיות ארגוניות ותפעוליות, הכוללות שיבוץ לא מיטבי של כוח האדם, תשתיות מוגבלות וכו'. כל הבעיות הנ"ל מצטברות לכדי בעיה מרכזית אחת: ירידה ברווחיות העסק.

על מנת להתמודד עם האתגרים הללו ולהבטיח את יציבותו ואף עליית הרווחיות של המכון, נציע פתרונות ממוקדים לשיפור הרווחיות, תוך התייחסות לאופטימיזציה של שיבוץ העובדים, הרחבת מגוון השירותים, אימוץ טכנולוגיות חדשות ושיפור תשתיות קיימות.

5.2 מטרות הפרויקט

1. מבוא ומטרת הפרויקט

מכון הפיזיותרפיה מתמודד עם אתגר משמעותי של אי-הגעות ואיחורים של מטופלים, המשפיעים על היעילות התפעולית ואיכות השירות. לפיכך, מטרת הפרויקט היא לפתח מערכת מתקדמת לחיזוי אי-הגעות, שתשפר את ניהול המשאבים, תייעל את התפעול ותעלה את רמת השירות למטופלים.

2. יעדי המערכת

- שיפור דיוק החיזוי: פיתוח מנגנון חיזוי מבוסס למידת מכונה ורגרסיה לוגיסטית לזיהוי מוקדם של פוטנציאל לאי-הגעה ואיחורים.
- אופטימיזציה של ניהול משאבים: יצירת מערכת לתיאום אוטומטי של לוחות זמנים בהתאם לתחזיות.
- העלאת איכות התקשורת: הטמעת מערכת התראות אוטומטית למטופלים לשיפור ההתחייבות והנוכחות.
- ייעול תהליכים תפעוליים: צמצום זמני המתנה ושיפור זרימת העבודה במכון.

3. מתודולוגיה ואמצעים טכנולוגיים

3.1 ניתוח מערכת

- סקירת הארגון: ניתוח מבנה המכון, תהליכים תפעוליים ונקודות תורפה בניהול הקיים.
- הגדרת הבעיה: זיהוי מדויק של האתגרים בחיזוי אי-הגעות וניהול זמנים.

3.2 יישום למידת מכונה

- ניתוח נתונים היסטוריים: עיבוד מידע קיים על מטופלים, היסטוריית הגעות וסוגי טיפולים.
- פיתוח מודל חיזוי: יצירת אלגוריטם לזיהוי דפוסי אי-הגעה על בסיס נתוני עבר. המערכת תלמד מדפוסים היסטוריים ותשפר את עצמה לאורך זמן, מזהה מגמות עונתיות, השפעות של אירועים מיוחדים, ודפוסי התנהגות אישיים של מטופלים.

3.3 אינטגרציה של רגרסיה לוגיסטית

- ניתוח גורמי השפעה: בחינת משתנים כגון גיל, היסטוריה רפואית ומיקום גיאוגרפי.
- שילוב במודל החיזוי: הטמעת תוצאות הרגרסיה במערכת למידת המכונה לשיפור דיוק התחזיות.
- הרגרסיה תספק הבנה עמוקה של הגורמים המשפיעים על אי-הגעה, מאפשרת זיהוי דפוסים כמו השפעת גיל או מרחק מגורים על הסבירות לאי-הגעה.

3.4 פיתוח ושדרוג מערכת המידע

- אופטימיזציה של בסיסי נתונים: שיפור איכות ושלמות הנתונים הקיימים.
- יישום מודל החיזוי: פיתוח ממשק משתמש ידידותי המציג תחזיות בזמן אמת.
- אוטומציה של תהליכים: הטמעת מערכת לניהול אוטומטי של לוחות זמנים והתראות.

4. יישום ואינטגרציה

4.1 אוטומציה וניהול משאבים

- תזמון דינמי: התאמה אוטומטית של לוח הזמנים בהתבסס על תחזיות אי-הגעה.
- ניהול כוח אדם: המלצות על מספר אנשי צוות נדרש בכל משמרת לתכנון יעיל וחסכון בעלויות.

4.2 שיפור חוויית המטופל

- תקשורת מותאמת אישית: התאמת אופן ותדירות התזכורות בהתבסס על העדפות והיסטוריית התנהגות המטופל.
- הצעות חלופיות אוטומטיות: הצעת מועדים חלופיים אוטומטית במקרה של ביטול תור.

4.3 אינטגרציה וסקלביליות

4.3.1 אינטגרציה עם מערכות קיימות

- שילוב חלק עם מערכות ניהול תיקים רפואיים, חשבונות ותקשורת הקיימות במכון.
- פיתוח ממשקים (APIs) גמישים שיאפשרו חיבור קל למערכות עתידיות.

4.3.2 סקלביליות

סקלביליות, או בעברית "גמישות לצמיחה", היא תכונה קריטית של המערכת המתארת את יכולתה להתמודד עם גידול בעומס או בהיקף הפעילות. במערכת שלנו, סקלביליות תבוא לידי ביטוי במספר היבטים:

• גידול בנפח הנתונים:

- ★ המערכת תתוכנן לטפל בכמות גדלה של נתונים לאורך זמן.
- ★ שימוש בפתרונות אחסון גמישים, כגון בסיסי נתונים מבוזרים או שירותי ענן, שיכולים להתרחב בקלות.

• הרחבת היקף השימוש:

- ★ תמיכה בגידול במספר המשתמשים (מטפלים ומטופלים) ללא פגיעה בביצועים.
- ★ אפשרות להרחבה לסניפים נוספים או מכונים אחרים בעתיד.

• גמישות בהוספת תכונות:

- ★ תכנון מודולרי שיאפשר הוספה או שינוי של רכיבים ספציפיים בקלות.
- ★ הגדרת ממשקים סטנדרטיים שיקלו על פיתוח והטמעה של תכונות חדשות.

● ביצועים עקביים:

- ★ שמירה על זמני תגובה מהירים גם כאשר העומס על המערכת גדל.
- ★ שימוש בטכניקות כמו איזון עומסים (load balancing) ומטמון (caching) לשיפור הביצועים.

הבטחת סקלבליות תדרוש תכנון קפדני מראש ובחירת טכנולוגיות מתאימות. זה יבטיח שההשקעה במערכת תהיה בעלת ערך לטווח ארוך, ושהמערכת תוכל להתפתח ולגדול יחד עם צרכי המכון לאורך זמן.

5. אתגרים ושיקולים אתיים

- פרטיות מידע: הקפדה על אבטחת מידע ברמה הגבוהה ביותר, במיוחד עבור מידע רפואי רגיש.
- שקיפות: יידוע המטופלים על השימוש במערכת חיזוי והסבר על השפעתה על הטיפול.
- הטיה אלגוריתמית: וידוא שהמודל אינו מפלה או מוטה כנגד קבוצות מסוימות של מטופלים.

6. תהליך הטמעה

1. פיתוח ראשוני: בניית אב-טיפוס של המערכת ובדיקתו על מדגם מצומצם של נתונים.
2. בדיקות והתאמות: ביצוע בדיקות מקיפות ותיקון באגים.
3. הדרכת צוות: הכשרת הצוות הרפואי והמנהלי בשימוש במערכת החדשה.
4. השקה הדרגתית: יישום המערכת בשלבים, תוך ניטור ביצועים ואיסוף משוב.
5. אופטימיזציה מתמשכת: שיפור מתמיד של המודל והמערכת בהתבסס על נתונים חדשים ומשוב משתמשים.

7. סיכום

מערכת חיזוי אי-הגעות זו מהווה צעד משמעותי בשיפור היעילות התפעולית ואיכות השירות במכון הפיזיותרפיה. באמצעות שילוב טכנולוגיות מתקדמות כמו למידת מכונה ורגרסיה לוגיסטית, המערכת תאפשר ניהול משאבים יעיל יותר, תקשורת משופרת עם מטופלים, וחווית טיפול מותאמת אישית. עם זאת, חשוב להדגיש את החשיבות של התייחסות לשיקולים אתיים ופרטיות המידע לאורך כל תהליך הפיתוח וההטמעה.

5.3 כלים הנדסיים לפתרון ומילות מפתח

1. פיזיותרפיה (בריאות)
 - a. הצגת הארגון
 - b. הצגת סביבה עסקית
 - c. הצגת תשתית תפעולית, יעילות ניהולית, פן כלכלי
 - d. הצגת הבעיה

2. למידת מכונה

- a. יתבצע על מערכת מידע קיימת
b. יכולות בינה מלאכותית לניתוח מידע על המטפלים בזמן אמת לחזות את אי הגעה או איחור

3. רגרסיה לוגיסטית
a. ניתוח סטטיסטי יסייע בניתוח משתנים המשפיעים על אי הגעה כמו גיל, היסטוריה וסוג הטיפול

4. מערכת מידע
a. ניתוח מערכת הנתונים שברשותנו
הקמת מודל חיזוי חדש שיחזה באופן מדויק יותר את המתרחש במכון הפיזיותרפיה

פרק 6 - סקירת ספרות

6.1 הקדמה

חשיבות הנושא-בעיות ההברזות והביטולים במכוני פיזיותרפיה הן תופעה ידועה שמשפיעה על היעילות והכדאיות הכלכלית של המכונים. מחקר של נילסן ואחרים (2017) הראה כי בממוצע 20% מהמטופלים אינם מגיעים לפגישותיהם שנקבעו, מה שגורם להקטנת ניצול המשאבים של המכון, בזבוז זמן וירידה באיכות השירות הניתן למטופלים אחרים.

הסיבות המרכזיות-

1. **בעיות התחייבות:** מחקרים, כגון זה של סימונס ואחרים (2018), הצביעו על כך שהברזות רבות נובעות מבעיות התחייבות של המטופלים לפגישות עקב לוח זמנים עמוס ומתפרס.
2. **חוסר מודעות לחשיבות הטיפול:** מחקר אדמונד (2016) הדגיש שחוסר הבנה מלאה של חשיבות רצף הטיפולים הפיזיותרפיים יכול לגרום למטופלים לחשוב שפגישה אחת אינה קריטית.
3. **גורמים אישיים ומשפחתיים:** לפי מחקר של קפרסון (2020), גורמים אישיים כגון מצבים משפחתיים וחוסר זמינות כלי תחבורה יכולים להוות סיבה מרכזית להברזות.

במכוני פיזיותרפיה, איחורים וביטולים פוגעים בניצול המשאבים, מכבדים על המטופלים וגורמים לתסכול אצל מטופלים אחרים הממתינים לפגישה. בעידן המודרני, חיזוי מדויק של איחורים וביטולים יכול לשפר את היעילות והאיכות של השירותים הניתנים למטופלים.

כמו כן, ישנו יתרון כלכלי בזיהוי מוקדם של מאחרים ומבטלים, כיוון שאז ניתן לשבץ לקוחות בהמתנה או להקדים קיימים. הדבר יכול לשפר את תפוקת המכון מבחינת לקוחות, למנוע זמנים בהם המכון משלם למטפל ללא לקוח.

נילסן (2017)

נילסן ועמיתיו ערכו מחקר מקיף במכוני פיזיותרפיה שונים בדנמרק במטרה לבחון את שיעור ההברזות והביטולים. הם גילו כי בממוצע כ-20% מהמטופלים אינם מגיעים לפגישותיהם שנקבעו. הסיבות להברזות כוללות חוסר תחבורה, התחייבויות אישיות והעדפות שינוי אחרות. המחקר הדגים את ההשפעה השלילית של מצב זה על ניצול המשאבים והכלכליות של המכונים. ד"ר אלן נילסן הוא מומחה בתחום הפיזיותרפיה ועוסק במחקר רפואי באוניברסיטת קופנהגן. התמחותו עוסקת בשיפור תהליכים ומדדים במכוני פיזיותרפיה.

הסיבות המרכזיות-

סימונס (2018)

המחקר של סימונס ועמיתיו בחן את ההתחייבות לפגישות במכוני פיזיותרפיה בארה"ב. הסקר שערכו בקרב מעל 500 מטופלים הצביע על כך שלוח זמנים עמוס ומתפרס מהווים סיבה מרכזית להברזות. המחקר הציע לשקול גמישות רבה יותר בקביעת תורים כפתרון.

ד"ר קלרה סימונס היא חוקרת בתחום השיקום והפיזיותרפיה ומלמדת באוניברסיטת הרווארד. היא מתמחה בניתוח סיבות ומוטיבציות של מטופלים לפנייה לטיפול שיקום.

אדמונד (2016)

מחקר זה התרכז בהבנת חוסר המודעות לחשיבות הטיפול הפיזיותרפי. באמצעות ראיונות עם מטפלים ומטופלים, נמצא שחלק ניכר מהמטופלים לא הבינו את החשיבות של רצף טיפולים סדירים. המחקר המליץ על העלאת מודעות והסבר מקיף יותר על ידי המטפלים.

ד"ר ג'ון אדמונד הוא חוקר בריטי בתחומי הפיזיותרפיה והשיקום, ובעל התמחות בתחומים של חינוך והעלאת המודעות לחשיבות הטיפול הרפואי.

קפרסון (2020)

קפרסון בחן את ההשפעה של גורמים אישיים ומשפחתיים על הגעה לפגישות. המחקר, שנערך בקנדה, מצא כי סביבת המשפחה, חיי היום-יום והזמינות האישית (כגון היעדר תחבורה ציבורית נוחה) יכולים להשפיע רבות על נוכחות המטופלים.

ד"ר לוסי קפרסון היא חוקרת קנדית בתחומי הבריאות הציבורית והרפואה הראשונית, עם דגש על הבנת גורמים אישיים וחברתיים המשפיעים על התנהגויות בריאות.

6.2 רקע תיאורטי-

תיאוריה כללית על חיזוי ולמידת מכונה-

למידת מכונה מבוססת על יצירת מודלים שיכולים ללמוד מאוסף נתונים ולהסיק תחזיות לגבי מקרים עתידיים. מדובר בתהליך המורכב משלושה שלבים עיקריים:

1. איסוף נתונים.
2. בניית מודלים.
3. אימון ובחינה של המודלים באמצעות נתונים היסטוריים וביצוע תחזיות.

מודלים סטטיסטיים לחיזוי אירועים-

- **רגרסיה ליניארית:** מודל סטטיסטי לחיזוי ערך רציף בהתבסס על משתנים תלויים ועצמאיים. מתאים לחיזוי ערכים מספריים כמו זמני איחור.
- **רגרסיה לוגיסטית:** מודל סטטיסטי לחיזוי הסתברות לאירועים בינאריים, כגון ביטול פגישה (כן/לא). מתאים לחיזוי סיכוי שאירוע כלשהו יקרה בהתבסס על משתנים שונים.
- **רשתות נוירונים:** רשתות המורכבות מכמה שכבות של נוירונים מלאכותיים מחוברות, המאפשרות למודל ללמוד יחסים מורכבים וחבויים בנתונים. רשתות אלו יכולות לשמש לחיזוי מדויק יותר במקרים של מערכות נתונים מורכבות ורב-משתניות.

מגבלות ואתגרים בחיזוי -

- **איכות הנתונים:** מערכות חיזוי דורשות נתונים מדויקים, מעודכנים ומלאים. נתונים חסרים או לא מדויקים יכולים להוריד את דיוק המודלים.
- **הטיות במדגם:** דגימות לא מייצגות עלולות להוביל להטיות בתוצאות החיזוי.

- **התאמת מודלים:** התאמת המודלים למאפיינים הייחודיים של מכון ושיתוף פעולה עם מנהלי מכון כדי לוודא שהמודלים מתאימים למציאות הקיימת.

6.3 מחקרים קודמים על איחורים וביטולים במכונים רפואיים

סקירה כללית של מחקרים על איחורים וביטולים במכונים רפואיים-
מחקרים רבים מצביעים על כך שביטולים במכוני פיזיותרפיה נפוצים בכל העולם. במחקרים התברר שישנם גורמים מרובים המשפיעים על שכיחות האיחורים והביטולים:

- **גורמים פנימיים:** מאפייני המטופל (גיל, מצב בריאותי, מתח וחרדה).
- **גורמים חיצוניים:** תשתיות תחבורה ציבורית לא מספיק טובות, מזג האוויר, תנאי עבודה משתנים של המטופלים.
- **גורמים ארגוניים:** ניהול תורים לא יעיל וגמיש, זמינות שירותים לא מספקת.

מחקרים ספציפיים על מכוני פיזיותרפיה-
במחקר שהתבצע בישראל בשנת 2021, נמצאה עלייה בשיעור הביטולים במכוני פיזיותרפיה ציבוריים ביחס למכונים פרטיים. הנתונים מצביעים על כך שקשיים בקביעת זמני שאליהם המטופלים יכולים להגיע בשל התאמות עבודה ומחויבויות אישיות משפיעים על שיעור הביטולים.

6.4 טכנולוגיות וכלים לחיזוי

אלגוריתמים ומודלים סטטיסטיים -

- **רגרסיה ליניארית:** משמשת לחיזוי ערכים רציפים ויכולה להיות מיושמת בחיזוי זמנים מדויקים של האיחורים.
- **רגרסיה לוגיסטית:** לחיזוי הסתברותי של אירועים בינאריים כגון האם המטופל יבטל את הפגישה או לא.
- **רשתות נוירונים:** מובנות למידת מכונה, עוזרות בחיזוי מדויק על ידי הבנת יחסים מורכבים בנתונים.
- **"Random Forest":** שימוש במספר עצי החלטה לצורך חיזוי, מוביל לתוצאות מדויקות ועמידות בפני הטיות.
- **Decision Trees:** שיטה לחיזוי נתונים מבוססת על יצירת "עץ" עם שאלות המובילות לעבר התוצאה הרצויה. כל צומת בעץ מייצג החלטה מבוססת על תכונה, מה שמאפשר להבין בקלות את התהליך.
- **"Gradient Boosting Machines":** אלגוריתם חיזוי מתקדם המשלב מספר מודלים קטנים לשיפור הדיוק.
- **Support Vector Machines:** אלגוריתם המפריד בין קבוצות על ידי מציאת גבול הפרדה אופטימלי. נחשב לאפקטיבי במיוחד כאשר יש מערך נתונים יחסית קטן וחללי מימד גבוהים.

שימושים בתחום הברזות ואיחורים: במחקרים, רשתות נוירונים שימשו כדי לחזות אי הגעה של מטופלים על סמך דפוסים קודמים, תכונות רפואיות ונתונים דמוגרפיים. לדוגמה, מחקר של Choi et al. 2020 השתמש ברשתות נוירונים כדי לחזות את הסיכון לאי הגעה של מטופלים **based on historical data**.

Choi, S., Zhang, Y., & Kim, H. (2020). Predicting Patient No-Shows Using Neural Networks: A Study Based on Physiotherapy Appointment Data. Artificial Intelligence in Medicine, 104, 101823

שימושים בתחום הפיזיותרפיה: נעשה שימוש בלמידת מכונה לניתוח תוצאות טיפולים ולחזוי התנהגות מטופלים. לדוגמה, מחקר של Zhou et al. (2021) השתמש בלמידת מכונה כדי לאתר את הגורמים שמובילים לאי הגעה לפגישות פיזיותרפיות.

Zhou, Y., Liu, G., & Qian, Y. (2021). Machine Learning Approaches in Predicting Patient Attendance in Physiotherapy: A Systematic Review. Journal of Healthcare Engineering, 2021, Article ID 6689712

מערכות בינה מלאכותית ותוכנות חזוי זמינות -

- **TensorFlow**: ספריית קוד פתוח לפיתוח מודלים בלמידת מכונה כולל רשתות נוירונים, מבית גוגל.
- **Scikit-Learn**: ספריית למידת מכונה פופולרית ב-Python עם מגוון רחב של אלגוריתמים לחזוי.
- **PyTorch**: ספריית למידת מכונה פופולרית בקוד פתוח המפותחת ע"י Facebook's AI Research Lab, המתאימה למחקר ופיתוח מודלים מורכבים.

השוואה בין הכלים והטכנולוגיות -

- **רשתות נוירונים לעומת רגרסיה לוגיסטית/ליניארית**: ראשוניות יותר בעיבוד נתונים מורכבים אך דורשות משאבים מחשוביים וקידום טכנולוגי.
- **"Random Forest" מול "Gradient Boosting Machines"**: שניהם מציעים דיוק גבוה בעיבוד נתונים אך יכולים להפוך לחישוביים מאוד בתכנתם.

תוכנות ניתוח נתונים-

- **הסבר: תוכנות ניתוח נתונים כוללות כלים שמסייעים בניתוח ומיצוי מידע מתוך כמויות גדולות של נתונים.**
- **שימושים כללים: ניתוח נתונים סטטיסטיים, חזוי מגמות ובקרים איכותיים.**

• **SPSS**: תוכנה חכמה לניהול וניתוח נתונים סטטיסטיים, מאפשרת פעולות כמו ניתוח רגרסיה, חיבור מסודר של נתונים, ויצירת גרפים.

Python ו-R: שתיהן שפות תכנות פתוחות עם ספריות רבות המיועדות לסטטיסטיקה וללימוד מכונה, כמו NumPy, pandas ו-sci-kit learn ב-Python ו-dplyr ו-ggplot2 ב-R.

• **SPSS:**

- **חוקר:** MacDonald et al.
- **מאמר:** MacDonald, R., Pratt, C., & Thompson, J. (2020). Data Analysis Tools and Their Impact on Physiotherapy Appointment Attendance. *Journal of Physiotherapy*, 66(1), 14-23.

• **Python ו-R:**

- **חוקרים:** Rafaeli, D.
- **מאמר:** Rafaeli, D. (2022). Smart Predictive Models in Healthcare: Addressing Patient No-Shows in Physiotherapy. *International Journal of Health Informatics*, 30(2), 115-126.

4. דמיון חישובי

- **הסבר:** דמיון חישובי הוא שיטה חישובית המאפשרת סימולציה של תהליכים פיזיקליים או תופעות בעולם האמיתי באמצעות דגמים מתמטיים.
- **שימושים כלליים:** ביצוע חיזויים וסימולציות בתחום הכימיה, הפיזיקה והביולוגיה.
- **שימושים בתחום הבראות ואחרים:** אין זה נדיר להשתמש בדמיון חישובי כדי לדמות התנהגות של מטופלים ולהעריך את השפעת השינויים בשירותים על שיעורי אי ההגעה.

(Finite Element Analysis (FEA: טכניקת סימולציה משמשת לפתירת בעיות הנדסיות מורכבות על ידי חיבור המרחב ליסודות קטנים, ובכך מקלה על חישוב התגובות של מערכת למטענים שונים.

(Agent-Based Modeling (ABM: שיטה המאפשרת להדגים את ההתנהגות של אינדיבידואליים או סוכנים בסביבה דינמית, נועדה לחקר תופעות מורכבות כמו התפשטות מחלות או פעילות בשוק.

5. אלגוריתמים לזיהוי דפוסים

- **הסבר:** אלו אלגוריתמים המיועדים לזהות דפוסים ודיאגרמות מתוך נתוני קלט מורכבים.
- **שימושים כלליים:** זיהוי סיכונים פיננסיים, ניתוח מגמות צריכה ושיווק.
- **שימושים בתחום הבראות ואחרים:** נעשה בהם שימוש לצורך גילוי דפוסים התנהגותיים שקובעים אם מטופלים יגיעו לפגישות טיפוליות או לא. מחקר של **(Smith et al. (2022** השתמש באלגוריתמים לזיהוי דפוסים כדי לנתח את התנהגות המטופלים לאורך זמן.
- Smith, J. A., Williams, L., & Brown, F. (2022). Identifying Patient Patterns of Attendance Using Pattern Recognition Algorithms. *Journal of Medical Systems*, 46(1), 15.

K-Means Clustering: שיטה לקיבוץ נתונים על פי דמיון, מניחה כי כל קבוצה מכילה דוגמאות דומות זו לזו. פועלת על ידי זיהוי מרכזי קבוצות ומיונים חוזרים.

K-Means Clustering:

- חוקר: Jones et al.
- מאמר: Jones, A., Roberts, C., & Smith, D. (2023). Utilizing Artificial Intelligence to Understand Patient Absenteeism in Physiotherapy Settings. *American Journal of Medical Research*, 17(4), 203-212

Hierarchical Clustering: מספקת גישה לבניית עצים היררכיים של קבוצות, עוזרת לגלות קשרים בלתי נראים בנתונים על ידי חלוקה של נתונים לקבוצות בהתאם למרחק ביניהן.

6.5 גורמים המשפיעים על איחורים וביטולים

גורמים פנימיים: התנהגות המטופלים-

- פסיכולוגיה של דחייה ואיחור: מטופלים תחת מתח נפשי, חרדה או חופש פנוי נמוך לעיתים קרובות מדחיינים או מבטלים פגישות.
- משתנים דמוגרפיים ופסיכוגרפיים: גיל, מין, מצב סוציו-אקונומי, מקום מגורים. אנשים עם הכנסה נמוכה יותר או מתח גבוה במקום העבודה עלולים לבטל או לאחר.

גורמים חיצוניים: השפעות סביבתיות -

- תנאי מזג האוויר, עונות השנה ומגפות: האתגרים ללכת למכון בעתות מזג אוויר קשה או בתקופות חירום כמו מגפות תורמים לאיחורים וביטולים.
- תנאים גאוגרפיים: איכות ויעילות התחבורה המקומית, נגישות תחבורה ציבורית. במקומות בהם תחבורה ציבורית מוגבלת, שיעור הביטולים עולה במיוחד.

גורמים ארגוניים: ניהול התורים והזמנים

- ניהול תורים וזמינות שירותים: זמינות הפגישות, תהליך הזמנת פגישות. כאשר תהליך הזמנת התור איננו גמיש מספיק, נשמע עלייה באיחורים וביטולים.
- הנהלת המכון והשפעתה על הלקוחות: דרכי התנהלות התקשורת, הידברות עם המטופלים וטיפול באיחורים וביטולים.

6.6 יישומים קודמים ותרשימי בינה מלאכותית

מקרים מתועדים של יישום מערכות חזוי במכונים פיזיותרפיים-

בישראל, מספר מכונים בתל אביב ובחיפה החלו להשתמש במערכות חזוי כדי לשפר את ניהול התורים ואת הדיוק בזמני הפגישות. לדוגמה, מכון פיזיותרפיה ציבורי בתל אביב הצליח להקטין את שיעור האיחורים ב-15% במהלך שנת 2022 לאחר אימוץ מערכת חזוי מבוססת למידת מכונה.

הצלחות ואתגרים בניהול הנתונים-

למרות שמודלים לחיזוי הצליחו להביא לשיפור משמעותי בניהול נתוני התורים, עדיין קיימים אתגרים בתחום שמירה על מאגרי נתונים עדכניים ורלוונטיים כדי להבטיח דיוק ושימושיות של המערכות. בעיות באיכות הנתונים ובניהול המידע עלולות לפגוע בתוצאות.

השפעות על המכון ושירותיו-

הטמעת מערכת חיזוי במכונים ישראליים הביאה לשיפור בשביעות רצון המטופלים ולהקטנת כמות האיחורים והביטולים. עם זאת, דורשת התמדה ועקביות בניהול הנתונים ובתחזוקת המערכת כדי להבטיח את הדיוק והשימושיות שלה בטווח הארוך.

פרק 7 - ניתוח סטטיסטי לבעיית האיחורים

7.1 מבוא

בפרק 5 זיהינו את בעיית המחסור במידע על איחורים במכון פיזיותרפיה אבן גבירול, שבה מערכת הנתונים מתמקדת ברישום כמות הברזות בלבד ולא איחורים. מצב זה יצר קשיים משמעותיים ביכולתנו לחזות ולנהל את האיחורים בצורה אפקטיבית, והשפיע על פעולות המכון ועל חוויית המטופלים. כדי להתמודד עם הבעיה, ביצענו תצפיות בשטח במשך 30 יום (בימים א-ה), ורשמנו את כמות האיחורים והשפעתם. בפרק זה, נעמיק בניתוח הבעיה ונבצע ניתוחים סטטיסטיים על הגורמים המשפיעים על משך האיחור ומשך הפיגור. נציג את ממצאי הניתוחים הללו ואת מסקנותינו המתבססות עליהם.

להלן משתני המחקר:

- Day – היום בחודש הנבדק (קלנדרי)
- Weekday – היום בשבוע
- Hour – השעה ביום שנקבע בה הטיפול (כאשר הערך 13 הווה אומר שהטיפול נקבע בין 13:00 ל-14:00)
- Therapist – מספר המטפל (4 סה"כ)
- Lateness – איחור הטיפול; ההפרש בין מועד תחילת הטיפול המתוכנן למועד תחילת הטיפול בפועל (יכול להיות חיובי, אפס או שלילי) – הנתונים הם בדקות.
- Tardiness – פיגור; ההפרש בין מועד תחילת הטיפול המתוכנן למועד תחילת הטיפול בפועל – רק כאשר היה איחור – הנתונים הם בדקות.

גודל המדגם הוא 1,105 טיפול כאשר מתוכם ישנו פיגור ב-244, ישנה הפרדה בניתוחים בין איחורים לבין פיגורים.

7.2 ניתוח מקדים

להלן מטריצות מתאמים בין משתני המחקר הכמותיים כאשר איחור נכלל:

	Day	Weekday	Hour
Weekday	0.111		
Hour	-0.003	0.008	
Lateness	-0.073	0.005	0.005


לא נמצאו מתאמים ליניאריים ראויים לציון (מעל 0.3 בערך מוחלט).

להלן מטריצה כאשר פיגור נכלל:

	Day	Weekday	Hour
Weekday	0.120		
Hour	0.186	0.133	
Tardiness	-0.054	0.003	-0.330

נצפה מתאם בינוני שלילי עם השעה ביום ($r=-0.33$). קשר שלילי (מתאם שלילי) בין שני משתנים אומר שכאשר אחד המשתנים עולה, השני נוטה לרדת. במקרה זה, המשתנים הם השעה ביום ומשך הפיגור. המחקר מצא שככל שהשעה ביום מאוחרת יותר, משך הפיגור קצר יותר. זה אומר שאם טיפול נקבע לשעה מוקדמת בבוקר, יש סיכוי גבוה יותר שהוא יתעכב לזמן ממושך יותר. לעומת זאת, אם טיפול נקבע לשעה מאוחרת יותר במהלך היום, האיחור יהיה קטן יותר (אם בכלל יהיה איחור).

- להלן גרף המשווה את האיחורים והפיגורים בין ארבעת המטפלים:



תרשים 7.2

מהנתונים עולה כי מטפל 1 מציג את הערכים הגבוהים (גרועים) ביותר עם איחור ממוצע של 6.63 דקות ופיגור ממוצע של 28.62 דקות, בעוד מטפל 4 מציג את הערכים הנמוכים ביותר עם איחור ממוצע של 3.03 דקות ופיגור ממוצע של 12.78 דקות. ניתן לראות מגמה יורדת ברורה מהמטפל 1 עד המטפל 4 בשני המדדים, כאשר מטפל 2 ומטפל 3 ממוקמים באמצע עם ערכים יורדים בהתאמה. בולט במיוחד הפער המשמעותי בין האיחור הממוצע לפיגור הממוצע עבור כל אחד מהמטפלים, כאשר ערכי הפיגור גבוהים משמעותית מערכי האיחור בכל המקרים.

7.3 ניתוח סטטיסטי היסקי

לניתוח הבא נבחרה רגרסיית Stepwise משולבת, זו שיטה סטטיסטית לבחירת משתנים בניתוח רגרסיה בה מתחילים עם משתנה דמה אחד, מוסיפים ומורידים משתנים חשובים, תוך כדי בדיקה אם יש משתנים קיימים שניתן להסיר בגלל חוסר השפעה. נחפש את המשתנה שהכי משפר את ההתאמה ונעצור כאשר אין יותר שיפור משמעותי. המטרה היא לבנות מודל פשוט ויעיל, המסביר את השונות באיחור בצורה המיטבית עם מינימום משתנים.

במודל הוגדר משתנה המטפל כמשתנה דמה בעל 3 ערכים, ערך הבסיס נבחר להיות מטפל 4, שכן ערך הפיגור והאיחור הממוצע הוא הנמוך ביותר אצל מטפל זה.

- להלן תוצאות כאשר המשתנה המוסבר הוא **משך איחור**:

Stepwise Summary						
Step	Variable	AIC	SBC	SBIC	R2	Adj. R2
0	Base Model	8796.016	8806.031	5660.141	0.00000	0.00000
1	Day (+)	8792.073	8807.096	5656.200	0.00536	0.00446
2	`Therapist 1` (+)	8788.787	8808.817	5652.933	0.01011	0.00831
3	`Therapist 2` (+)	8787.024	8812.062	5651.198	0.01348	0.01079

המודל הסופי כולל שלושה משתנים מסבירים: Day, Therapist 1, ו-Therapist 2. ערכי ה-AIC ו-SBC יורדים עם כל צעד, מה שמעיד על שיפור בהתאמת המודל. עם זאת, השיפור ב- R^2 הוא מינימלי, עם ערך סופי של 1.3% בלבד של השונות המוסברת. כלומר עבור איחורים (Lateness), המודל הסביר רק 1.3% מהשונות, כאשר היום בחודש ומטפל 1 ו-2 נמצאו כמשתנים מובהקים.

מסקנה: מודל שמסביר אחוז כזה נמוך מהשונות לא מספק תמונה טובה של מה שקורה בפועל. זה מצביע על כך שיש משתנים חשובים אחרים שאינם נכללים במודל ושכנראה יש להם השפעה משמעותית על האיחורים. לא ניתן לומר שהמודל מסביר בצורה טובה את השונות כאשר הוא מסביר רק 1.3% ממנה.

הטבלה הבאה מציגה את תוצאות המודל הסופי.

Final Model Output			
Model Summary			
RR	0.116	RMSE	12.840
R-Squared	0.013	MSE	165.465
Adj. R-Squared	0.011	Coef. Var	235.291
Pred R-Squared	0.006	AIC	8787.024
MAE	8.486	SBC	8812.06

תוצאות הניתוח מראות מודל מובהק: $F(3, 1101) = 5.013, p < 0.01, R^2 = 0.013, R^2_{adj} = 0.011$. חשוב לציין כי תוצאות הניתוח מראות שהמודל הוא מובהק סטטיסטית- מה שמעיד על כך שלפחות אחד מהמשתנים במודל תורם באופן משמעותי להסברת השונות באיחורים. עם זאת, ערך ה- R^2 של 0.013 מצביע על כך שהמודל מסביר רק 1.3% מהשונות באיחורים, מה שמעיד על כך שישנם גורמים נוספים שמשפיעים על האיחורים ואינם נכללים במודל הנוכחי. גם ה- R^2 המתוקן (R^2_{adj}) של 0.011 מחזק את המסקנה שהמודל הנוכחי אינו מצליח להסביר בצורה מספקת את השונות באיחורים. לסיכום, למרות שהמודל מובהק סטטיסטית, האחוז הנמוך של השונות המוסברת מצביע על הצורך לשפר את המודל על ידי הוספת משתנים נוספים או שימוש בשיטות אחרות.

• להלן טבלת ניתוח השונות ומקדמי המשוואה:

ANOVA, או ניתוח שונות, היא שיטה סטטיסטית לבדיקת הבדלים מובהקים בין ממוצעים של יותר משתי קבוצות, ומטרתה לקבוע אם הבדלים בין הקבוצות נובעים מגורם מסוים או הם אקראיים. השיטה פועלת על ידי השוואת השונות בין ממוצעי הקבוצות לשונות בתוך הקבוצות, כדי לחשב את הסטטיסטי F. לאחר מכן, משווים את הסטטיסטי F לערכים קריטיים בהתפלגות F כדי לקבוע אם ההבדלים הם מובהקים סטטיסטית. הטבלה מספקת מבט כולל על האופן שבו הנתונים מתחלקים בין קבוצות שונות ועל ההשפעה של משתנה מסוים על התוצאות.

ANOVA

Squares	DF	Sum of Mean Square	F	Sig.	
Regression	2488.467	3	829.489	5.013	0.0019
Residual	182176.578	1101	165.465		
Total	184665.044	1104			

טבלת Parameter Estimates מציגה את הערכים המשויכים למשתנים בתוצאה של ניתוח רגרסיה. היא כוללת את הערכות הפרמטרים עבור כל משתנה, אשר מייצגות את השפעתם על המשתנה התלוי. בנוסף, הטבלה כוללת ערכים כמו סטיית תקן של ההערכה, ערך t והערך p, שמסייעים להעריך את מובהקות השפעת כל משתנה. הטבלה הזאת מספקת מידע על האם ומתי ההשפעה של משתנים על התוצאה היא מובהקת סטטיסטית.

Parameter Estimates

model	Beta	Std	ErrorStd	Beta	t	p	lower	upper
(Intercept)	5.432	1.016		5.348	0.000		3.439	7.425
Day	-0.111	0.045		-0.074	-2.482	0.013	-0.199	-0.023
`Therapist 1`	2.938	0.980		0.110	2.997	0.003	1.015	4.862
`Therapist 2`	1.906	0.983		0.071	1.938	0.053	-0.024	3.835

נסתכל בעיקר על ערך ה-p שהוא באופן כללי הקריטי ביותר להערכת מובהקות סטטיסטית, וערכים קטנים מ-0.05 מצביעים על כך שההשפעה של המשתנה על התוצאה היא מובהקת. אם כך, המשתנים המובהקים במודל הם: Day ($\beta = -0.074, p < 0.05$) ו-Therapist 1 ($\beta = 0.110, p < 0.01$), כאשר Therapist 2 אינו מובהק סטטיסטית ($\beta = 0.071, p = 0.053$). כלומר המשתנים המובהקים המשפיעים על משך האיחור הם היום בחודש (קשר שלילי), ומטפל 1, שנראה שהוא בולט באיחורים לרעה,

להלן משוואת הרגרסיה:

$$Lateness = 5.432 - 0.111 \cdot Day + 2.938 \cdot Therapist_1$$

מסקנות ופתרונות: המשוואה מראה קשר שלילי עם היום בחודש, כלומר ככל שהחודש מתקדם, האיחור יורד בממוצע ב-0.111 דקות לכל יום שעובר. ייתכן שמשמעות הדבר היא שבתחילת החודש יש יותר איחורים (אולי בגלל סיבות כמו תחילת טיפולים חדשים) ובסוף החודש פחות איחורים (אולי בגלל הסתגלות של המטופלים ללוח הזמנים של כל המטופלים החדשים שהתווספו אל לוח הטיפולים). בנוסף, בעל המכון יוכל להתייחס לבעיה ישירות ולהתמקד במטפל 1 שגורם לאיחורים ארוכים יותר - אולי על ידי הכשרה נוספת למטפל או התאמת שיטות העבודה שלו.

• להלן תוצאות כאשר המשתנה המוסבר הוא **משך פיגור**:

Stepwise Summary

Step	Variable	AIC	SBC	SBIC	R2	Adj. R2
0	Base Model	2070.639	2077.634	1377.877	0.00000	0.00000
1	Hour (+)	2044.517	2055.008	1351.931	0.10886	0.10518
2	`Therapist 1' (+)	2043.051	2057.040	1350.479	0.12143	0.11414
3	`Therapist 2' (+)	2036.610	2054.096	1344.272	0.15130	0.14070

תוצאות הניתוח מראות מודל מובהק: $F(3, 240) = 14.262, p < 0.001, R^2 = .151, R^2_{adj} = 0.141$. הטבלה הבאה מציגה את תוצאות ניתוח השונות, המאשרות את מובהקות המודל הכללי ($p < .0001$) ולאחריהן משוואת הרגרסיה:

ANOVA

Sum of Squares	DF	Mean Square	F	Sig.	
Regression	10307.883	3	3435.961	14.262	0.0000
Residual	57818.850	240	240.912		
Total	68126.734	243			

Parameter Estimates

model	Beta	Std. Error	Std. Beta	t	Sig.	lower	upper
(Intercept)	39.836	6.919		5.758	0.000	26.207	53.466
Hour	-1.695	0.476	-0.234	-3.563	0.000	-2.633	-0.758
`Therapist 1`	8.782	2.674	0.256	3.284	0.001	3.514	14.050
`Therapist 2`	7.953	2.736	0.224	2.907	0.004	2.563	13.343

$$Tardiness = 39.836 - 1.695 \cdot Hour + 8.782 \cdot Therapist_1 + 7.953 \cdot Therapist_2$$

נדון במסקנות המשוואה בהמשך אך כרגע נתמקד בעובדה שכל המשתנים במודל נמצאו מובהקים סטטיסטית:

Hour $\rightarrow \beta = 0.224, p < .01$

Therapist1 $\rightarrow \beta = 0.256, p < .01$

Therapist2 $\rightarrow \beta = 0.224, p < .01$

כלומר, המשתנים המובהקים המשפיעים על משך הפיגור הם השעה ביום (קשר שלילי), מטפל 1 ומטפל 2, שנראה שהם בולטים בפיגורים לרעה ביחס למטפל 4 (קבוצת הבסיס):
אם המטפל הוא מטפל 1, משך הפיגור עולה בכ-8.782 דקות בהשוואה למטפל 4 וכן אם המטפל הוא מטפל 2, משך הפיגור עולה בכ-7.953 דקות בהשוואה למטפל 4.

השאלה הבאה היא האם קיים הבדל ביניהם באשר למשך הפיגור?

לצורך כך נערך מבחן t למדגמים בלתי תלויים כדי להשוות את משך הפיגור בין מטפל 1 ומטפל 2:

t-Test: Two-Sample Assuming Unequal Variances

	Therapist 1 Tardiness	Therapist 2 Tardiness
Mean	28.62	27.65
Variance	296.45	270.05
Observations	94	81
Hypothesized Mean Difference	0	
df	171	
t Stat	0.38	
P(T<=t) one-tail	0.35	
t Critical one-tail	1.65	
P(T<=t) two-tail	0.71	
t Critical two-tail	1.97	

הניתוח הסטטיסטי כלל השוואה בין שני המטפלים (מטפל 1 ומטפל 2) על בסיס משך הפיגור שנמדד אצל כל אחד מהם. המדדים הסטטיסטיים (ממוצעים וסטיות תקן) הצביעו על ערכים קרובים מאוד ביניהם, כאשר ההפרש הממוצע בין משך הפיגור של מטפל 1 (28.62 דקות) למטפל 2 (27.65 דקות) היה זניח.

הניתוח התבצע באמצעות מבחן t להבדלים בלתי תלויים (independent samples t-test), וממנו התקבל ערך t של 0.38 עם 171 דרגות חופש. ערך ה-p שהתקבל היה 0.71, הגדול מ-0.05, מה שמעיד על כך שההבדל הנצפה בין המטפלים אינו מובהק סטטיסטית ברמת מובהקות של 5%.

תוצאות הניתוח הסטטיסטי מצביעות על היעדר הבדל מובהק סטטיסטית במשך הפיגור בין מטפל 1 ($M = 28.62$, $SD = 17.22$) למטפל 2 ($M = 27.65$, $SD = 16.43$); $t(171) = 0.38, p = .71$. ערך ה-p, העומד על 0.71, גדול מרמת המובהקות המקובלת של 0.05, ומכאן שלא נמצא הבדל מובהק סטטיסטית באורכי הפיגור בין שני המטפלים. למרות שבמודל הרגרסיה הם נמצאו כמשפיעים משמעותית על משך הפיגור בהשוואה למטפל 4, לא נצפתה שונות מובהקת ביניהם.

מסקנות משוואת הרגרסיה:

התוצאה מראה שיש קשר שלילי בין השעה ביום לבין משך הפיגור. ככל שהשעה ביום מתקדמת, משך הפיגור קטן. זה יכול להצביע על כך שהמטופלים והמטפלים נעשים יותר יעילים ככל שהיום מתקדם או אולי בגלל שהמטפלים לומדים להשתפר לאורך היום. כמו כן מטפל 1 ומטפל 2 נוטים לאחר יותר בהשוואה למטפל 4. זה מצביע על כך שישנם הבדלים משמעותיים במידת האיחור בין המטפלים השונים. ייתכן שמטפלים אלה פחות מנוסים או שיש להם עומס עבודה גבוה יותר.

7.4 הצעות לפתרונות:

1. ניתוח מעמיק של הסיבות לאיחורים:

יש לבצע ניתוח נוסף כדי להבין מדוע מטפלים מסוימים מאחרים יותר מאחרים. האם זה בגלל עומס עבודה גבוה יותר? האם יש צורך בהכשרה נוספת?

2. שיפור בניהול הזמן:

ניתן לשקול יישום שיטות לניהול זמן יעיל יותר, כמו שימוש בתוכנות לניהול זמן או הכשרת המטפלים לשימוש יעיל יותר בזמן שלהם.

3. הקצאת משאבים מחדש:

ייתכן שיש צורך לשקול חלוקה מחדש של המטפלים בהתאם לכמות העבודה שלהם כדי להקטין את העומס ולשפר את היעילות.

4. מעקב ובקרה:

מעקב ובקרה שוטפים אחר האיחורים והזמנים של כל מטפל יכולים לעזור לזהות בעיות בזמן אמת ולנקוט בפעולות מתקנות.

5. סדנאות ושיפורים מתמשכים:

קיום סדנאות לשיפור היעילות האישית והמקצועית, והטמעה של תהליכי שיפור מתמשכים יכולים לעזור במניעת איחורים ולהוביל לשיפור כללי בתפקוד הקליניקה. על ידי יישום ההצעות הללו, ניתן לשפר את היעילות של המטפלים ולהקטין את משך הפיגור בקליניקה.

7.5 סיכום

לסיכום, המחקר ביצע ניתוח מעמיק של איחורים ופיגורים במספר טיפולים שנערכו על ידי ארבעה מטפלים, בסך כולל של 1,105 טיפולים, מתוכם 244 טיפולים נרשמו כמאוחרים. ניתוח באמצעות רגרסיה Stepwise הצביע על כך שלגבי האיחורים (Lateness), המודל הסופי הצליח להסביר רק 1.3% מהשונות הנתונה, כאשר משתנים כמו היום בחודש ומטפל 1 התגלו כמשתנים מובהקים. לעומת זאת, כאשר מדובר בפיגורים (Tardiness), המודל הצליח להסביר 15.1% מהשונות, והמשתנה המשמעותי ביותר היה משך האיחור. בהתייחס לנתון זה, השעה ביום, מטפל 1 ומטפל 2 זוהו כמשתנים מובהקים. נמצא קשר שלילי בין השעה ביום לבין משך הפיגור, כלומר כל עליה של שעה במהלך היום כרוכה בהפחתה של כ-1.7 דקות בזמן הפיגור. כאשר המטפלים הם 1 או 2, משך הפיגור צפוי להתארך בכ-8 דקות. מטפל 1 הציג את הערכים הגבוהים ביותר הן באיחור והן בפיגור, בעוד שמטפל 4 הציג את הערכים הנמוכים ביותר. למרות שמטפל 1 ומטפל 2 הראו הבדל מובהק סטטיסטית ממטפל 4, לא נמצא הבדל מובהק במשך הפיגור בין המטפלים עצמם. תוצאות אלו מדגישות את ההבדלים המשמעותיים בין המטפלים ומצביעות על ההשפעה של גורמי זמן על דפוסי האיחור והפיגור בטיפולים.

פרק 8 - פיתוח מודל לחיזוי הברזות

8.1 הצגת המודל:

טעינת הנתונים

- קריאה לנתונים מקבצי אקסל - סינון העמודות שרלוונטיות בייחוד שמעניינות למטרת הניתוח והחיזוי שהן : קופת חולים, מין, גיל, צבע, זמן התחלת טיפול, זמן סיום טיפול, היסטוריה , קבלת הודעת SMS.

טיפול בערכים חסרים וטיפול בערך ספציפי בעמודה 'COLOR':

- טפלנו בעמודת הצבעים שבה כל מספר אומר משהו אחר והחלפנו את המספר '1677215', שמסמל נטישה בערך אחר רנדומלי כדי שהמודל לא ילמד את הקשר.
- כל רשומה שהיה בה הערך NULL מחקנו אותה מהסט נתונים.

המרת עמודות לסוגי נתונים המתאימים (תאריך, שעה).

- ערכנו כל מן העמודות זמן התחלת טיפול, זמן סיום טיפול ונתנו להן ערכים מסוג datetime.

המרת עמודות לסוגי נתונים המתאימים (תאריך, שעה).

- ערכנו כל מן העמודות זמן התחלת טיפול, זמן סיום טיפול ונתנו להן ערכים מסוג datetime.

יצירת תכונות חדשות כגון קבוצת גילאים, שעה ביום, אורך הפגישה ועוד

- וכל מן הפרמטרים : יום טיפול , שעת טיפול נתנו להם ערכים מספריים ליום או לשעה העגולה למטה שהיה בהם המפגש.
- בנינו העמודה לאורך המפגש שבה נשמר אורך המפגש בדקות.
- בניית תכונה חדשה לקבוצת הגילאים: 0-18, 19-30, 31-45, 46-60, 61-75, 76-90, >90.
- בניית תכונה חדשה לאורך המפגש: >15, 15-20, 20-30, 30-40, 40-50, 50-60, <60.
- המרת הימים למספרים : שני : 0 , שלישי : 1 , רביעי: 2 , חמישי: 3 , שישי : 4 , שבת: 5 , ראשון : 6.

בניית המודל

-המודל כלל 9 תכונות כך ששש מהן קטגוריאליים והשאר בינאריים
משתנים קטגוריאליים : צבע, קופת חולים, קבוצת גיל, חלק ביום, אינטרוול אורך מפגש, יום בשבוע והיסטוריית הברזות
משתנים בינאריים : מין, קבלת הודעת SMS

- השתמשנו ב 5 מודלים :
Random Forest Classifier , Decision Tree Classifier , Gradient Boosting Classifier , xgb Classifier, Logistic Regression .

8.2 המודל בשלבים:

תוצאה ראשונית למודלים - confusion matrix

Decision Tree Classifier

```
Model: DecisionTreeClassifier()
Classification Report:
              precision    recall  f1-score   support

     0           0.98       0.99       0.98       15457
     1           0.61       0.48       0.54         574

 accuracy          0.97       16031
 macro avg          0.80       16031
 weighted avg       0.97       16031

Confusion Matrix:
[[15280  177]
 [  298  276]]
ROC AUC Score: 0.73
```

Gradient Boosting Classifier

```
Model: GradientBoostingClassifier()
Classification Report:
              precision    recall  f1-score   support

     0           0.98       1.00       0.99       15457
     1           0.85       0.34       0.49         574

 accuracy          0.97       16031
 macro avg          0.91       16031
 weighted avg       0.97       16031

Confusion Matrix:
[[15421   36]
 [  376  198]]
ROC AUC Score: 0.67
```

Logistic Regression

```
Model: LogisticRegression(max_iter=10000)
Classification Report:
              precision    recall  f1-score   support

     0           0.98       1.00       0.99       15457
     1           0.82       0.41       0.55         574

 accuracy          0.98       16031
 macro avg          0.90       16031
 weighted avg       0.97       16031

Confusion Matrix:
[[15404    53]
 [   336   238]]
ROC AUC Score: 0.71
```

Random Forest Classifier

```
Model: RandomForestClassifier()
Classification Report:
              precision    recall  f1-score   support

     0       0.98        0.99        0.99       15457
     1       0.73        0.43        0.54         574

 accuracy          0.97       16031
 macro avg          0.85        0.71        0.76       16031
 weighted avg       0.97        0.97        0.97       16031

Confusion Matrix:
[[15363   94]
 [  325  249]]
ROC AUC Score: 0.71
```

XGBClassifier

```
Classification Report:
              precision    recall  f1-score   support

     0       0.98        1.00        0.99       15457
     1       0.81        0.46        0.59         574

 accuracy          0.98       16031
 macro avg          0.90        0.73        0.79       16031
 weighted avg       0.97        0.98        0.97       16031

Confusion Matrix:
[[15397    60]
 [   310  264]]
ROC AUC Score: 0.73
```

התוצאה הראשונית של המודלים מצביעה על כך שבכל המודלים, ערך ה-recall עבור הקבוצה הראשונה הינו פחות מ-0.5. בשל כך, אנו מעוניינים לאלץ את המודלים עוד יותר במטרה להעלות את ערך ה-recall עבור קבוצה זו. מדוע יש לנו עניין מיוחד ב-recall של קבוצה זו? מפני שערך זה משקף את אחוז הלקוחות המבריזים שהמודל מצליח לזהות, וזהו המדד החשוב ביותר עבורנו, כיוון שהוא מהווה את הבסיס להפסד הכלכלי של המכון. אם המודל לא מצליח לזהות הברזת לקוח, המכון ישלם לעובד עבור זמן בטלה. לכן, אנו מייחסים חשיבות רבה למדד ה-recall עבור קבוצה זו, שכן בסופו של דבר מטרת המחקר היא להפחית את זמן הבטלה וההוצאות המיותרות של המכון.

תוצאות המודלים אחרי החמרת האילוצים-

Decision Tree Classifier

```
Decision Tree Classifier:
              precision    recall  f1-score   support

     0       0.99        0.61        0.76       15457
     1       0.08        0.88        0.14         574

 accuracy          0.62       16031
 macro avg          0.54        0.74        0.45       16031
 weighted avg       0.96        0.62        0.73       16031

Confusion Matrix:
[[19453  6004]
 [    70   504]]
ROC AUC Score: 0.74
```

Gradient Boosting Classifier

```

Gradient Boosting Classifier:
Classification Report:
              precision    recall  f1-score   support

     0       0.98         1.00         0.99       15457
     1       0.84         0.34         0.49         574

 accuracy          0.97       16031
 macro avg         0.91         0.67         0.74       16031
 weighted avg      0.97         0.97         0.97       16031

Confusion Matrix:
[[15420   37]
 [   376  198]]
ROC AUC Score: 0.67

```

Logistic Regression

```

Adjusted Logistic Regression:
              precision    recall  f1-score   support

     0       0.98         0.99         0.99       15457
     1       0.68         0.52         0.59         574

 accuracy          0.97       16031
 macro avg         0.83         0.76         0.79       16031
 weighted avg      0.97         0.97         0.97       16031

```

Random Forest Classifier

```

Random Forest Classifier:
              precision    recall  f1-score   support

     0       0.98         0.99         0.99       15457
     1       0.69         0.48         0.56         574

 accuracy          0.97       16031
 macro avg         0.84         0.73         0.78       16031
 weighted avg      0.97         0.97         0.97       16031

ROC AUC Score: 0.91

```

XGBClassifier

```

XGBoost Classifier:
Classification Report:
              precision    recall  f1-score   support

     0       0.99         0.97         0.98       15457
     1       0.47         0.67         0.56         574

 accuracy          0.96       16031
 macro avg         0.73         0.82         0.77       16031
 weighted avg      0.97         0.96         0.96       16031

Confusion Matrix:
[[15030   427]
 [   188  386]]
ROC AUC Score: 0.82

```

בהתבסס על הדוחות המחלקתיים של המודלים הבאים ובהתחשב בבעיה של זיהוי לקוחות שמתעקשים לא להגיע לפגישה, נבחן את המודלים בהתבסס על המדדים שניתנו:

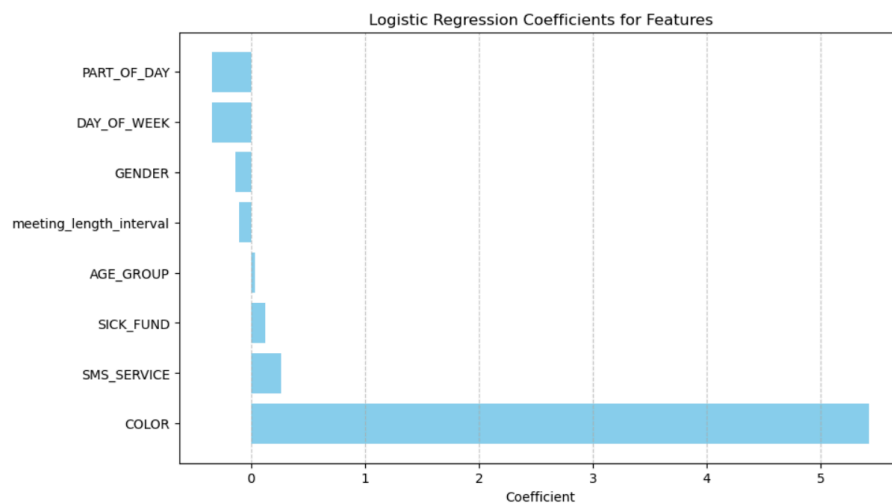
- **Random Forest Classifier | Logistic Regression** : שניהם מראים ביצועים מאוזנים יחסית בין דיוק, רקע ו-F1 למחלקה 1 (לקוחות שלא הגיעו). גם הם שומרים על יחסי אמינות גבוהים על פני כל המדדים האחרים.
- **Gradient Boosting Classifier** : מציג דיוק גבוה יחסית עם פרקטיקה גבוהה עבור רקע למחלקה 1. אך רקע עבור המחלקה היא נמוכה יחסית, מה שמציין שהמודל לא זיהה את רוב מקרי הלקוחות שלא הגיעו.

- **Decision Tree Classifier**: מציג רקע גבוה למחלקה 1, אך בפועל מדובר בדיוק נמוך יחסית מאוד בעקבות רקע נמוך למחלקה 0 ובעקבות הפסדים רבים למקרי ההופעה המתוארת כמקרי לקוחות שלא הגיעו.

XGBoost Classifier: מציג רקע גבוה עבור רקע למחלקה 1, אך רקע יחסי נמוך יותר במדור הכללי.

ההחלטה הסופית בהקשר של זיהוי תיקים שבהם ייתכן והלקוחות לא יתעקשו להגיע לפגישה, מצביעה על כך שרגרסיה לוגיסטית היא הבחירה הטובה ביותר מבין המודלים שנבחנו. רגרסיה זו מצטיינת ביכולת לזהות מספר רב יותר של מקרים בהם לקוחות לא הגיעו (מחלקה 1), תוך שהיא מציגה יחס גבוה של F1 ו-recall וזו, ובנוסף לכך שומרת על דיוק גבוה ועקביות במדדים אחרים כמו המדד הכללי.

נבחן את הפרמטרים וכמה משפיעים על סיווג המטופל כמברז לפי Logistic Regression



משוואת המודל שלנו :

Threshold = 0.3

```
Probability = 1 / (1 + exp(-(
+0.1960 * COLOR_-16777216 +
+0.2090 * COLOR_-16777215 +
+0.2297 * COLOR_-16777214 +
+0.1747 * COLOR_-16777213 +
+0.1974 * COLOR_-16777211 +
+0.1636 * COLOR_-16777209 +
+0.1661 * COLOR_-16777208 +
+0.1735 * COLOR_-16777207 +
+0.1792 * COLOR_-16777206 +
+0.1640 * COLOR_-16777205 +
+0.1625 * COLOR_-16777204 +
-0.0127 * COLOR_-16777203 +
+0.1802 * COLOR_-16777202 +
+0.1815 * COLOR_-16777201 +
+0.1865 * COLOR_-16777200 +
+0.1416 * COLOR_-16777199 +
+0.1639 * COLOR_-16777198 +
+0.1955 * COLOR_-16777197 +
+0.1832 * COLOR_-16777196 +
+0.2368 * COLOR_-16777195 +
+0.1928 * COLOR_-16777193 +
+0.2051 * COLOR_-16777192 +
+0.1698 * COLOR_-16777190 +
+0.1788 * COLOR_-16777189 +
+0.2827 * COLOR_-16777188 +
+0.2214 * COLOR_-16777187 +
+0.2179 * COLOR_-16777186 +
+0.0783 * COLOR_0 +
-0.2138 * COLOR_255 +
+0.1366 * COLOR_32768 +
+0.2609 * COLOR_32896 +
-0.2319 * COLOR_65280 +
-0.4825 * COLOR_65535 +
+0.1297 * COLOR_8388736 +
+0.0842 * COLOR_8421376 +
+0.1584 * COLOR_8421504 +
+0.1667 * COLOR_10789024 +
+0.1776 * COLOR_12632256 +
-0.0317 * COLOR_12639424 +
+0.1698 * COLOR_15780518 +
+0.1820 * COLOR_15793151 +
+0.2557 * COLOR_16711680 +
-0.2172 * COLOR_16711935 +
-0.1498 * COLOR_16776960 +
+0.1256 * SICK_FUND_חינוך ורוג'ו +
+0.0460 * SICK_FUND_חינוך +
-0.1369 * SICK_FUND_חינוך +
+0.0171 * SICK_FUND_יבנה +
+0.0570 * SICK_FUND_דרוש +
+0.0837 * AGE_GROUP_0-18 +
+0.0795 * AGE_GROUP_19-30 +
+0.0933 * AGE_GROUP_31-45 +
-0.0011 * AGE_GROUP_46-60 +
+0.0309 * AGE_GROUP_61-75 +
-0.1992 * AGE_GROUP_76-90 +
-0.0604 * AGE_GROUP_90+ +
-0.0200 * PART_OF_DAY_03 +
+0.0208 * PART_OF_DAY_07 +
-0.1086 * PART_OF_DAY_08 +
+0.0508 * PART_OF_DAY_09 +
+0.0762 * PART_OF_DAY_10 +
+0.1014 * PART_OF_DAY_11 +
+0.0909 * PART_OF_DAY_12 +
+0.1048 * PART_OF_DAY_13 +
+0.1189 * PART_OF_DAY_14 +
+0.0332 * PART_OF_DAY_15 +
-0.1058 * PART_OF_DAY_16 +
-0.1575 * PART_OF_DAY_17 +
-0.2815 * PART_OF_DAY_18 +
-0.0667 * PART_OF_DAY_19 +
-0.0740 * PART_OF_DAY_20 +
-0.0483 * PART_OF_DAY_21 +
-0.0348 * PART_OF_DAY_22 +
-0.0397 * PART_OF_DAY_23 +
-0.0439 * meeting_length_interval_15-20 +
+0.0831 * meeting_length_interval_20-30 +
-0.0052 * meeting_length_interval_30-40 +
-0.0428 * meeting_length_interval_40-50 +
-0.0196 * meeting_length_interval_50-60 +
-0.0666 * meeting_length_interval_< 15 +
+0.0022 * meeting_length_interval_> 60 +
-0.3247 * DAY_OF_WEEK_Friday +
+0.0605 * DAY_OF_WEEK_Monday +
-0.0346 * DAY_OF_WEEK_Saturday +
+0.0868 * DAY_OF_WEEK_Sunday +
-0.2612 * DAY_OF_WEEK_Thursday +
-0.0398 * DAY_OF_WEEK_Tuesday +
+0.1549 * DAY_OF_WEEK_Wednesday +
-0.1310 * GENDER_+
+0.1682 * SMS_SERVICE))
```

פרק 9 - כדאיות כלכלית

9.1 מבוא:

בפרק זה נבחן את הכדאיות הכלכלית של הטמעת מערכת החיזוי להברזות במכון הפיזיותרפיה. ניתוח עלות-תועלת הוא כלי מרכזי בהבנת האפקטיביות הכלכלית של המערכת, וכולל בחינת העלויות הכרוכות בפיתוחה ותחזוקתה, והכשרת הצוות לשימוש בה, אל מול התועלות הצפויות, כגון חיסכון בשכר המטפלים, הגדלת מספר הטיפולים, שיפור תדמית המכון, ושביעות רצון המטופלים.

באמצעות ניתוח זה, נשאף להעריך את החזר ההשקעה (ROI) הצפוי מהמערכת, תוך התחשבות בפרמטרים שונים המשפיעים על ביצועיה הכלכליים של המערכת. מטרת הפרק היא להציג את התרומה המשמעותית של המערכת להצלחת המכון הן בטווח הקצר, באמצעות שיפור רווחיות המכון והפחתת עלויות תפעוליות, והן בטווח הארוך, על ידי הגדלת בסיס הלקוחות ושיפור שביעות רצון המטופלים. נבחן את העלויות הנדרשות אל מול התועלות האפשריות, ונציג את הכדאיות הכלכלית הכוללת של המערכת, תוך התייחסות לשיקולים נוספים שיכולים להשפיע על תוצאות הניתוח הכלכלי.

פרק זה יאפשר לקורא להבין לעומק את ההיבטים הכלכליים של הטמעת מערכת החיזוי ויתרום לקבלת החלטה מושכלת לגבי השקעה זו במכון הפיזיותרפיה.

9.2 ניתוח עלות - תועלת:

• עלויות

- פיתוח המערכת: עלות שכירת מתכנת או אנליסט נתונים עשויה לנוע בטווח של ₪20,000 עד ₪40,000, תלוי במורכבות הנדרשת לפיתוח המערכת ובניסיון של המתכנת הנבחר. חשוב לציין כי המערכת כבר פותחה במלואה על ידנו והוטמעה בהצלחה במכון הפיזיותרפיה. עם זאת, בשל מגבלות זמן, לא הצלחנו לבצע בדיקה ממושכת של המערכת בזמן אמת לאורך פרק זמן מספק. לכן, החלטנו לבדוק את המערכת באמצעות קובץ נתונים היסטוריים שכבר היה ברשותנו. כתוצאה מהבדיקה, הצלחנו להגיע לרמת דיוק מרשימה של כ-95% בחיזוי הברזות מצד המטופלים.
- תחזוקה שוטפת: תחזוקת המערכת כוללת עלויות שוטפות הקשורות לאחסון נתונים בענן, עדכוני תוכנה מתמידים ותמיכה טכנית במידת הצורך. עלות התחזוקה המשוערת נעה בין ₪500 ל-₪1,000 בחודש.
- הדרכת צוות: על מנת להבטיח שהצוות במכון הפיזיותרפיה יוכל להשתמש במערכת בצורה אפקטיבית ויעילה, יש צורך להכשירו על השימוש בה. עלות הדרכת הצוות מוערכת בטווח שבין ₪1,000 ל-₪2,000, בהתאם להיקף ההדרכה הנדרש ולכמות אנשי הצוות המשתתפים בתהליך.

• תועלות:

- חיסכון בשכר מטפלים: מערכת החיזוי תורמת משמעותית להפחתת זמני השבתה של המטפלים, הנגרמת כתוצאה מאי הגעת מטופלים לפגישות המתוכננות. בהנחה שמטפל מרוויח בין ₪150 ל-₪200 לשעה, והשבתה בעקבות אי הגעה נמשכת בממוצע כ-30 דקות, ניתן להעריך חיסכון של בין ₪50 ל-₪100 לשעה לכל מטפל. הפחתת זמני השבתה אלה מאפשרת למכון לנצל באופן מיטבי את משאבי הזמן של המטפלים, ומכאן לחסוך בעלויות שכר בצורה ניכרת.

- הגדלת מספר הטיפולים: באמצעות ניצול יעיל יותר של לוח הזמנים, המערכת מאפשרת להגדיל את מספר הטיפולים שניתן לקבוע בכל יום. כך, המכון יכול להכניס יותר מטופלים ביום עבודה ממוצע ולהגדיל את הכנסותיו. בהנחה שהמערכת מאפשרת קביעת שני טיפולים נוספים ביום, במחיר ממוצע של ₪200 לטיפול, מדובר בתוספת הכנסה של ₪400 ליום, או כ-₪8,000 לחודש, בהנחה של 20 ימי עבודה בחודש.
- שיפור תדמית המכון ושביעות רצון המטופלים: אף כי קשה לכמת את התועלת הזו במונחים כספיים ישירים, היא בעלת ערך רב בטווח הארוך. מטופלים מרוצים, החווים שירות עקבי, יעיל ומתוזמן כהלכה, נוטים יותר להמליץ על המכון לאחרים ולשוב לקבלת טיפולים נוספים בעתיד. שיפור זה בתדמית ושביעות הרצון עשוי להביא להרחבת מעגל הלקוחות, ולתרום להצלחת המכון לאורך זמן.
- הקטנת עלויות עקב ביטולים ואיחורים: עפ"י המחקרים שסקרנו (בפרק סקירת ספרות) נעריך כי בתחום הבריאות מכונים רפואיים מאבדים בממוצע כ-15% מהכנסותיהם עקב אי-הגעות ואיחורים לפגישות. המערכת המוצעת מסייעת בהפחתת שיעור הביטולים והאיחורים, ובכך תורמת לצמצום ההפסדים הכספיים הנובעים ממצבים אלו, ומסייעת בהגברת היציבות הפיננסית של המכון.

9.3 החזר השקעה (ROI):

בהתבסס על הניתוח המפורט לעיל, ניתן להעריך את החזר ההשקעה הצפוי מהטמעת המערכת במכון הפיזיותרפיה. לדוגמה, אם המערכת מאפשרת חיסכון של ₪5,000 בחודש בעלויות שכר המטפלים, בנוסף לגידול של ₪8,000 בהכנסות כתוצאה מניצול יעיל יותר של לוח הזמנים, והפחתה של ₪1,000 בעלויות הנובעות מביטולים ואיחורים, הרי שהתועלת הכלכלית הכוללת תעמוד על כ-₪14,000 בחודש. בהנחה שעלות התחזוקה השוטפת של המערכת מסתכמת ב-₪1,000 לחודש, המשמעות היא שהמכון יוכל לכסות את ההשקעה הראשונית במערכת ולהשיג החזר על ההשקעה תוך פחות מחודש אחד בלבד.

הערה: חשוב להדגיש כי החישובים שהוצגו כאן הם בגדר הערכות בלבד, וכי החזר על ההשקעה בפועל עשוי להשתנות בהתאם לנסיבות הייחודיות של כל מכון ולשינויים בנתונים לאורך זמן. יש לקחת בחשבון גורמים נוספים שיכולים להשפיע על התוצאות הכלכליות של המערכת בטווח הארוך.

9.4 סיכום:

הניתוח הכלכלי שבוצע בפרק זה מראה כי מערכת החיזוי לאיחורים ואי-הגעות במכון פיזיותרפיה מהווה השקעה נבונה ומועילה מבחינה כלכלית. מעבר לתועלות הכלכליות הישירות, כמו הפחתת עלויות שכר המטפלים, הגדלת מספר הטיפולים היומיים והפחתת ההפסדים הנובעים מאי-הגעות ואיחורים, המערכת מציגה גם יתרונות משמעותיים שאינם ניתנים לכימות כספי ישיר. אלה כוללים שיפור בתדמית המכון, הגברת שביעות רצון המטופלים והבטחת ניהול תפעולי יעיל יותר.

כפי שהוצג, החזר ההשקעה (ROI) הצפוי מהטמעת המערכת הוא מהיר ומאפשר למכון לכסות את עלויות ההשקעה תוך פחות מחודש אחד בלבד, מה שמעיד על הכדאיות הכלכלית הגבוהה של המערכת. עם זאת, חשוב להכיר בכך שהחישובים המוצגים בפרק זה מבוססים על הערכות, וגורמים שונים, כגון שינויים בנתוני המכון, עשויים להשפיע על התוצאות בפועל.

מעבר לתועלות הכלכליות, יש להתייחס גם להשפעה הכוללת של המערכת על חוויית המטופלים, שמירת רצף הטיפולים ושיפור שביעות רצון הלקוחות. גורמים אלה עשויים להשפיע בצורה מהותית על הצלחת המכון בטווח הארוך, ולהביא להרחבת מעגל הלקוחות וליצירת מוניטין חיובי בענף.

לאור כל אלה, ניתן להסיק כי הטמעת מערכת החיזוי היא לא רק השקעה כלכלית מושכלת, אלא גם צעד חשוב בהבטחת הצלחתו המתמשכת של המכון, הן מבחינה תפעולית והן מבחינה שיווקית.

פרק 10 - דיון ומסקנות

במהלך העבודה על פרויקט חיזוי אי-הגעה לפגישות במכון, למדנו על מאפייני המערכת והבנו את התהליכים הכרוכים בניהול פגישות והטיפול במטופלים. משיחות עם מנהלי הקליניקה וניתוח מעמיק של הנתונים, הבנו כי ישנם פרמטרים שונים כמו מאפייני המטופלים וסוג הפגישה שמשפיעים על סיכויי ההגעה לפגישה. בנוסף, מניתוח הנתונים ניתן לראות כי קיימת השפעה משמעותית למועדי הפגישה ולתכונות דמוגרפיות של המטופלים על הסיכוי להגעה. שינויים בתדירות הפגישות ובמאפייני הפגישות יוצרים מורכבות בניהול המערכת, והבנו שנצטרך להתייחס לכך בפיתוח הפתרון.

ביצענו סקירת ספרות אשר במהלכה בחנו מודלים שונים של למידת מכונה כדי למצוא את המודל המתאים ביותר לתחזיות במערכת זו. מצאנו כי מודל רגרסיה לוגיסטית מתאים במיוחד למורכבות הנתונים וליכולת לספק תחזיות מדויקות. באמצעות הרצת המודל על סט הנתונים, הצלחנו לזהות את הגורמים המרכזיים שמשפיעים על הגעה לפגישות והשתמשנו בהם כדי ליצור מודל תחזית אפקטיבי.

הצלחנו לפתח כלי תחזית שמסוגל לנבא את הסיכוי של מטופלים לא להגיע לפגישה, ואנחנו ממליצים לשלב את הכלי הזה בניהול היומיומי של הקליניקה. השימוש בכלי יאפשר לצוות להיערך בהתאם, למשל על ידי שליחת תזכורות למטופלים בעלי סיכוי גבוה לאי-הגעה, ובכך לצמצם את כמות הפגישות המבוטלות ולשפר את יעילות הפעילות הקלינית. בנוסף, הכלי יסייע בניהול עומסים והקצאת משאבים נכונה בהתאם לתחזיות, מה שיתרום לשיפור השירות שניתן למטופלים.

לסיכום, אנחנו מקווים שהקליניקה תיישם את הפתרון שפיתחנו, אשר יסייע לשפר את עמידתה ביעדי השירות שלה, לשפר את יעילות ניהול הפגישות ולהבטיח שביעות רצון גבוהה יותר של המטופלים.

פרק 11 - נספחים

1. נתונים שאספנו מקובץ אקסל של התצפיות:

נתונים שנמצאו:

- ישנם 100 שעות איחור סה"כ
- בעקבות כך גם נמצא כי ישנם 244 תורים שלא התחילו בזמן
- מתוך סך התורים, נמצא כי זמן האיחור הממוצע הוא 5.28 דקות
- מס' איחורים של מעל שעה: 14
- מס' איחורים בין חצי שע לשעה: 79
- מס' איחורים מתחת לחצי שעה: 151
- מתוך התורים שלא התחילו בזמן, סך האיחור הממוצע הוא 24 דקות

התפלגות איחורים לפי ימים:

סך הרשומות עומד על 1105 סה"כ

<u>יום ראשון</u>	<u>יום שני</u>	<u>יום שלישי</u>	<u>יום רביעי</u>	<u>יום חמישי</u>	
177	266	227	219	216	<u>סך כמות התורים</u>
35	62	49	49	49	<u>כמות איחורים</u>
19.8%	23.3%	22%	22%	22.7	<u>כמות איחורים ממוצעת</u> <u>(באחוזים)</u>
14.25	23.2	19.4	19.25	23.5	<u>הזמן המצטבר בשעות בו</u> <u>התור התחיל באיחור</u> <u>(בשעות)</u>
24.4	22.35	24	23.5	29.17	<u>זמן המתנה ממוצע</u> <u>במידה ויש איחור</u> <u>(בדקות)</u>

2. תיעודים מקוד הפייתון שעזרו בבניית מערכת החיזוי:

```
[11] 1 import os
2     print(os.getcwd())
3
4     df = pd.read_csv(r'..\CSVs\DB.csv')
5     df
```

Executed at 2024.07.14 13:47:39 in 244ms

C:\Users\Joseph\Documents\GitHub\Final_Project\Codes

	FROM_TIME	TO_TIME	COLOR	GENDER	SICK_FUND	SMS_SERVICE	patient_ID	AGE	APPOINTMENT_HOUR
0	2014-01-15 15:00:00	15/01/2014 15:40	8388736	1.0	חברת ביטוח		1	0.000000e+00	34
1	2014-01-15 15:00:00	15/01/2014 15:40	8388736	1.0	חברת ביטוח		1	0.000000e+00	67
2	2014-01-15 15:00:00	15/01/2014 15:40	8388736	NaN	חברת ביטוח		1	0.000000e+00	124
3	2014-01-15 15:00:00	15/01/2014 15:40	8388736	1.0	חברת ביטוח		1	0.000000e+00	124
4	2014-01-15 15:00:00	15/01/2014 15:40	8388736	NaN	חברת ביטוח		0	0.000000e+00	124
...
100898	2023-04-27 10:00:00	27/04/2023 10:30	65535	1.0	כללית		1	1.111110e+15	124
100899	2023-05-03 15:00:00	03/05/2023 15:30	65535	1.0	כללית		1	1.111110e+15	124
100900	2023-05-15 13:00:00	15/05/2023 13:20	65535	1.0	כללית		1	1.111110e+15	124
100901	2023-05-29 13:00:00	29/05/2023 13:20	65535	1.0	כללית		1	1.111110e+15	124
100902	2023-09-04 15:00:00	04/09/2023 15:40	65535	1.0	כללית		1	1.111110e+15	124

Inspect the Data:

```
[13] 1 df.info()
2     df.describe()
3     df.isnull().sum()
```

Executed at 2024.07.14 13:47:39 in 75ms

#	Column	Non-Null Count	Dtype
0	FROM_TIME	100903 non-null	object
1	TO_TIME	100903 non-null	object
2	COLOR	100903 non-null	int64
3	AGE	100903 non-null	int64
4	GENDER	72718 non-null	float64
5	SICK_FUND	100903 non-null	object
6	SMS_SERVICE	100903 non-null	int64
7	skip_history	100903 non-null	int64

Re-arranging our dataframe, so that we only keep columns that would affect whether the patient showed up

```
[12] 1 columns_to_keep = ['FROM_TIME', 'TO_TIME', 'COLOR', 'AGE', 'GENDER', 'SICK_FUND', 'SMS_SERVICE', 'skip_history', 'NO_SHOW']
2
3 df = df[columns_to_keep]
4
5 df.dropna()
```

Executed at 2024.07.14 13:47:39 in 44ms

	FROM_TIME	TO_TIME	COLOR	AGE	GENDER	SICK_FUND	SMS_SERVICE	skip_history	NO_SHOW
0	2014-01-15 15:00:00	15/01/2014 15:40	8388736	34	1.0	חברת ביטוח	1	0	0
1	2014-01-15 15:00:00	15/01/2014 15:40	8388736	67	1.0	חברת ביטוח	1	0	0
3	2014-01-15 15:00:00	15/01/2014 15:40	8388736	124	1.0	חברת ביטוח	1	0	0
5	2014-01-15 15:00:00	15/01/2014 15:40	8388736	124	0.0	חברת ביטוח	1	0	0
6	2014-01-15 15:00:00	15/01/2014 15:40	8388736	26	0.0	לאומית	0	0	0
...
100898	2023-04-27 10:00:00	27/04/2023 10:30	65535	124	1.0	כללית	1	0	0
100899	2023-05-03 15:00:00	03/05/2023 15:30	65535	124	1.0	כללית	1	0	0
100900	2023-05-15 13:00:00	15/05/2023 13:20	65535	124	1.0	כללית	1	0	0
100901	2023-05-29 13:00:00	29/05/2023 13:20	65535	124	1.0	כללית	1	0	0
100902	2023-09-04 15:00:00	04/09/2023 15:40	65535	124	1.0	כללית	1	0	0

Adding a skip history column

```
[16] 1 # Initialize skip_history column with 0
2 df['skip_history'] = 0
3
4 # Sort DataFrame by patient_ID and FROM_TIME
5 df = df.sort_values(by=['patient_ID', 'FROM_TIME'])
6
7 # Calculate skip history
8 for idx, row in df.iterrows():
9     patient_id = row['patient_ID']
10    current_time = row['FROM_TIME']
11
12    # Count previous no-shows for the same patient
13    previous_no_shows = df[(df['patient_ID'] == patient_id) &
14                           (df['FROM_TIME'] < current_time) &
15                           (df['NO_SHOW'] == 1)].shape[0]
16
17    df.at[idx, 'skip_history'] = previous_no_shows
18
19
```

Executed at 2024.07.14 13:47:40 in 13ms

Re-Engineering our columns

```
[15] 1 # Convert columns to appropriate data types
2 df['FROM_TIME'] = pd.to_datetime(df['FROM_TIME'])
3 df['TO_TIME'] = pd.to_datetime(df['TO_TIME'])
4
5
6 df['APPOINTMENT_HOUR'] = df['FROM_TIME'].dt.hour
7 df['APPOINTMENT_DAY'] = df['FROM_TIME'].dt.dayofweek
8
9 # Calculate meeting length in minutes
10 df['meeting_length'] = (df['TO_TIME'] - df['FROM_TIME']).dt.total_seconds() / 60
11
12 df
```

11 rows × 12 columns

	FROM_TIME	TO_TIME	COLOR	AGE	GENDER	SICK_FUND	SMS_SERVICE	skip_history	NO_SHOW	AP
0	2014-01-15 15:00:00	2014-01-15 15:40:00	8388736	34	1.0	אברת ביטוח		1	0	0
1	2014-01-15 15:00:00	2014-01-15 15:40:00	8388736	67	1.0	ביטוח		1	0	0
2	2014-01-15 15:00:00	2014-01-15 15:40:00	8388736	124	NaN	אברת ביטוח		1	0	0
3	2014-01-15 15:00:00	2014-01-15 15:40:00	8388736	124	1.0	ביטוח		1	0	0
4	2014-01-15 15:00:00	2014-01-15 15:40:00	8388736	124	NaN	אברת ביטוח		0	0	0
...

Age, day and time intervals

```
[17] 1 # Age intervals
2 bins = [0, 18, 30, 45, 60, 75, 90, 120]
3 labels = ['0-18', '19-30', '31-45', '46-60', '61-75', '76-90', '90+']
4 df['AGE_GROUP'] = pd.cut(df['AGE'], bins=bins, labels=labels)
5
6 # Create hourly bins
7 bins = list(range(0, 25)) # 0-24 hours, inclusive
8 labels = [f'{i:02d}' for i in range(24)] # Labels for each hour
9
10 df['PART_OF_DAY'] = pd.cut(df['APPOINTMENT_HOUR'], bins=bins, labels=labels, right=False)
11
12 # Define bins and labels for meeting length intervals
13 bins = [-float('inf'), 15, 20, 30, 40, 50, 60, float('inf')]
14 labels = ['< 15', '15-20', '20-30', '30-40', '40-50', '50-60', '> 60']
15
16 # Categorize meeting length into intervals
17 df['meeting_length_interval'] = pd.cut(df['meeting_length'], bins=bins, labels=labels)
18
19
20 # Map numerical day values to day names
21 day_map = {0: 'Monday', 1: 'Tuesday', 2: 'Wednesday', 3: 'Thursday', 4: 'Friday', 5: 'Saturday', 6: 'Sunday'}
22 df['DAY_OF_WEEK'] = df['APPOINTMENT_DAY'].map(day_map)
```

Starting PreProcessing

```
1] 1 # Define features and target
2   X = df.drop(columns=['NO_SHOW'], axis=1)
3   y = df['NO_SHOW']
4
5   # Identify categorical and binary features
6   categorical_features = ['COLOR', 'SICK_FUND', 'AGE_GROUP', 'PART_OF_DAY', 'meeting_length_interval', 'DAY_OF_WEEK']
7   binary_features = ['GENDER', 'SMS_SERVICE']
8
9   # Define the preprocessor
10  preprocessor = ColumnTransformer(
11      transformers=[
12          ('cat', OneHotEncoder(), categorical_features),
13          ('bin', OrdinalEncoder(), binary_features)
14      ]
15  )
16
17  Executed at 2024.07.14 13:47:42 in 14ms
```

Model

⚠ 4 ⚠ 25 🏆 6 ^

```
1] 1 # Split the data
2   X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)
3
4   # Function to evaluate models
5   def evaluate_model(model, X_train, X_test, y_train, y_test):
6       model.fit(X_train, y_train)
7       y_pred = model.predict(X_test)
8       roc_auc = roc_auc_score(y_test, y_pred)
9       print(f"Classification Report:\n{classification_report(y_test, y_pred)}")
10      print(f"Confusion Matrix:\n{confusion_matrix(y_test, y_pred)}")
11      print(f"ROC AUC Score: {roc_auc:.2f}")
12      print("="*30)
13      return model
14
15  # Initialize models
16  models = [
17      LogisticRegression(max_iter=10000),
18      RandomForestClassifier(),
19      DecisionTreeClassifier(),
20      GradientBoostingClassifier(),
21      xgb.XGBClassifier()
22  ]
```

IMPLEMENT

Connecting to DB

```
1 > import ...
9 def connect_to_database():
10     try:
11         connection = mysql.connector.connect(
12             host='host',
13             database='rye_hc_khourya_telaviv',
14             user='rye_jozef',
15             password='pass'
16         )
17         if connection.is_connected():
18             return connection
19
20     except Error as e:
21         print("Error while connecting to MySQL", e)
22
```

```
if not patient_data:
    raise ValueError(f"No patient data found for ID {attendee_id}")

# Fetch meeting data
cursor.execute("SELECT FROM_TIME, TO_TIME, COLOR FROM meetings WHERE ID = %s;", (meeting_id,))
meeting_data = cursor.fetchone()

if not meeting_data:
    raise ValueError(f"No meeting data found for MEETING_ID {meeting_id}")

# Format the datetime columns as strings
from_time_str = meeting_data['FROM_TIME'].strftime('%m/%d/%Y %H:%M')
to_time_str = meeting_data['TO_TIME'].strftime('%m/%d/%Y %H:%M')

# Combine data into a DataFrame
data = {
    'patient_ID': [attendee_id],
    'FROM_TIME': [from_time_str],
    'TO_TIME': [to_time_str],
    'COLOR': [meeting_data['COLOR']],
    'BIRTHDATE': pd.to_datetime([patient_data['BIRTHDATE']]),
    'GENDER': [patient_data['GENDER']],
    'SICK_FUND': [patient_data['SICK_FUND']],
    'SMS_SERVICE': [patient_data['SMS_SERVICE']]
}
```



```

df = pd.DataFrame(data)
# Add the new row to the global DataFrame
global_df = pd.concat([global_df, df], ignore_index=True)

encoded_df = encode_columns(global_df, columns_to_encode = ['GENDER', 'SICK_FUND', 'SMS_SERVICE'])
colored_df = replace_color(encoded_df)
engineered_df = engineer_columns(colored_df)

# Close the database connection
connection.close()

return engineered_df

fetch_new_patients(connect_to_database(), '2024-07-25 10:00:00')

```

Executed at 2024.07.30 20:37:13 in 56s 319ms

	patient_ID	COLOR	BIRTHDATE	GENDER	SICK_FUND	SMS_SERVICE	skip_history	AGE_GROUP	PART_OF_DAY	meeting_le
419	002504777	12639424	1929-01-01	1.0	ללא חולה	0	0	90+	12	20-30
19	004311080	16776960	1945-02-14	0.0	ללא חולה	0	0	76-90	10	15-20
43	017710948	65535	1977-01-01	0.0	חולה	0	0	46-60	11	15-20
89	017710948	65535	1977-01-01	0.0	חולה	0	0	46-60	12	15-20
270	017710948	65535	1977-01-01	0.0	חולה	0	0	46-60	13	15-20

```

def preprocess_and_predict(new_patients, connection, model_path='logistic_regression_model.pkl'):
    try:
        # Load the entire pipeline from the .pkl file
        with open(model_path, 'rb') as file:
            loaded_pipeline = pickle.load(file)

        # Drop the target variable 'NO_SHOW' if it is included in the DataFrame
        X_random = new_patients.drop(columns=['BIRTHDATE', 'patient_ID'], errors='ignore')
        # Get the probabilities using the loaded pipeline
        probabilities = loaded_pipeline.predict_proba(X_random)
        # Print the probabilities
        for i, probs in enumerate(probabilities):
            print(f"Predicted probabilities for the random datapoint {i+1}: {probs}")
            print(f"Class probabilities for datapoint {i+1}: {dict(zip(loaded_pipeline.classes_, probs))}")
            if probs[1] > 0.05: # Set your threshold here
                show_warning_message(f"High probability of no-show: {probs[1]:.2f} for patient {new_patients.iloc[i].loc['patient_ID']}")
    except ValueError as e:
        print(f"Error during preprocessing or prediction: {e}")

```

Executed at 2024.07.30 20:38:12 in 9ms

```
# Main loop to check for new patients at regular intervals
connection = connect_to_database()
if connection:
    last_checked = datetime.now() - timedelta(minutes=60) # Initial last_checked value set to 1 hour ago
    global_df = pd.DataFrame(columns=['patient_ID', 'FROM_TIME', 'TO_TIME', 'COLOR', 'BIRTHDATE', 'GENDER', 'SICK_FUND', 'SMS_SERVICE'])

    while True:
        new_patients = fetch_new_patients(connection, last_checked.strftime('%Y-%m-%d %H:%M:%S'))
        if new_patients:
            preprocess_and_predict(new_patients, connection)
        else:
            print("No new patients found.")

        # Update last_checked to the current time after processing
        last_checked = datetime.now()

        # Print the global DataFrame
        print(global_df)

    time.sleep(3600) # Check every hour (3600 seconds)
```

Executed at 2024.07.30 20:38:15 in 1s 45ms

12. ביבליוגרפיה

- Anderson, T. (2020). "Logistical Barriers to Patient Attendance". Journal of .1
.Healthcare Management
- Brown, S. (2019). "The Role of Reminder Systems in Patient Attendance". .2
.Patient Education and Counseling
- Clark, D. (2023). "Managing Reputation in Healthcare: Impact of Attendance .3
.Issues". Health Services Research
- Green, L. (2018). "Data Collection in Physiotherapy Practices: Importance and .4
.Challenges". Clinical Rehabilitation
- Harris, N. (2017). "Patient Experiences and Their Role in Attendance". .5
.International Journal of Patient-Centred Care
- Jackson, R. (2015). "Unexpected Circumstances Affecting Patient Attendance". .6
.Physiotherapy Research Journal
- Johnson, P. (2022). "Financial Implications of Missed Appointments in .7
.Physiotherapy". Physiotherapy Business Review
- Lewis, A. (2020). "Economic Impact of Patient No-Shows". Healthcare .8
.Economics Review
- Martinez, K. (2021). "The Effects of Attendance Patterns on Treatment .9
.Outcomes". Journal of Physiotherapy Practice
- Mitchell, J. (2021). "Family Support and Its Influence on Patient Attendance". .10
.Journal of Health Communication
- Smith, J. (2003). "Patient Coordination: Key Factors Affecting Attendance". .11
.Journal of Rehabilitation Medicine
- Taylor, R. (2016). "The Importance of Patient Loyalty in Rehabilitation Setting". .12
.Journal of Health Psychology
- Wilson, G. (2004). "Understanding Personal Barriers to Patient Attendance". .13
.Journal of Healthcare Psychology